

UNIVERSIDADE FEDERAL RURAL DO RIO DE JANEIRO
INSTITUTO MULTIDISCIPLINAR

RAFAEL VIEIRA DA SILVA
HELCIO DUARTE DANTAS

**DataRural: Um Repositório
Institucional de Datasets para a
UFRRJ**

Prof. Filipe Braidão do Carmo, D.Sc.
Orientador

Nova Iguaçu, Setembro de 2026

DataRural: Um Repositório Institucional de Datasets para a UFRRJ

Rafael Vieira da Silva

Helcio Duarte Dantas

Projeto Final de Curso submetido ao Departamento de Ciência da Computação do Instituto Multidisciplinar da Universidade Federal Rural do Rio de Janeiro como parte dos requisitos necessários para obtenção do grau de Bacharel em Ciência da Computação.

Apresentado por:

Rafael Vieira da Silva

Helcio Duarte Dantas

Aprovado por:

Prof. Filipe Braida do Carmo, D.Sc.

Prof. Bruno José Dembogurski, D.Sc.

Prof. Marcel William Rocha da Silva, D.Sc.

NOVA IGUAÇU, RJ - BRASIL

Setembro de 2026

Agradecimentos

Rafael Vieira da Silva

Agradeço, em primeiro lugar, a Deus por me permitir chegar até aqui, e a todas as pessoas que, por meio de suas orações e de sua presença, contribuíram de alguma forma para a minha caminhada.

À minha avó, Maria de Lourdes, que, para mim, foi muito mais do que uma avó. Sempre fez o possível e o impossível para que eu continuasse meus estudos. Infelizmente, não pôde ver a conclusão desta etapa, mas tenho certeza de que, onde quer que esteja, está orgulhosa.

Aos meus pais, Rodrigo e Reylla, pelo apoio incondicional e por me guiarem pelos caminhos certos da vida. Essa conquista não é só minha, mas de vocês também.

À minha prima Flavia, que é como uma irmã para mim. Entre brigas e risadas, sempre estive ao meu lado nos momentos mais difíceis. E à sua mãe, Fátima, que, junto dela, alegrava até os dias mais escuros, mas que, assim como minha avó, deixa saudades que não cabem em palavras.

Aos amigos que a graduação me deu, companheiros nos mais diversos desafios, desde as chuvas até as matérias que pareciam impossíveis. Um agradecimento especial ao Helcio, que estive ao meu lado na construção deste trabalho, e aos demais: Pedro “Albergue”, “Magé”, Mariana, Pedro Guedes, Rafaela, Hélio e Davi.

Por fim, agradeço ao Clube de Regatas do Flamengo, que me proporcionou incontáveis alegrias ao longo desses anos e que, à sua maneira, também fez parte desta jornada.

Helcio Duarte Dantas

Agradeço à minha mãe, Emanuelle, e ao meu pai, Julio, por todo o apoio e por me proporcionarem as condições para chegar até aqui. Ao longo da minha vida, vocês estiveram ao meu lado e me ajudaram a seguir em frente. A conclusão desta etapa também é fruto do cuidado e da dedicação de vocês, a quem sou profundamente grato.

À minha irmã Sofia, que me proporcionou diversos momentos de alegria durante essa jornada e me ensinou a dar mais valor às coisas simples da vida.

À Gata Gorda, minha falecida gata que tornou os dias mais cinzentos melhores e me deu motivação para continuar seguindo em frente

Ao meu amigo Rafael Vieira, pela amizade e pela parceria durante este projeto e em tantos outros trabalhos acadêmicos. Também aos meus amigos Rafael “Magé” e Pedro “Albergue”, pelo companheirismo em todos os trabalhos acadêmicos que realizamos juntos. A parceria de vocês fez parte de tantos momentos da graduação e tornou essa trajetória mais leve e especial.

Agradeço também aos demais amigos que me ajudaram nas diversas disciplinas da faculdade, compartilhando conhecimentos e enfrentando comigo os desafios de cada etapa. Em especial, ao Hélio, pela sua amizade e pela sua incrível ajuda nas matérias ao longo dessa caminhada. Cada um de vocês contribuiu para que eu chegasse até aqui.

Aos meus professores da universidade, pelos conhecimentos compartilhados e pela orientação ao longo da minha formação. A dedicação de vocês ao ensino foi uma fonte de inspiração. Sou grato por terem contribuído para o meu desenvolvimento acadêmico.

Por fim, agradeço a Hideaki Anno por sua obra *Neon Genesis Evangelion*, que me levou a refletir profundamente sobre a vida e influenciou minhas escolhas ao longo desta etapa.

RESUMO

DataRural: Um Repositório Institucional de Datasets para a UFRRJ

Rafael Vieira da Silva e Helcio Duarte Dantas

Setembro/2026

Orientador: Filipe Braidão do Carmo, D.Sc.

A gestão de dados é essencial para a continuidade de atividades de pesquisa, extensão e administração em universidades. No entanto, os conjuntos de dados produzidos nessas instituições frequentemente permanecem dispersos em arquivos locais e sistemas sem integração, carentes de documentação, controle de acesso e preservação de histórico, o que dificulta sua localização, interpretação e reutilização. Diante dessa problemática, o presente trabalho descreve o desenvolvimento do DataRural, uma plataforma web institucional criada para centralizar e organizar a publicação e o compartilhamento de datasets na Universidade Federal Rural do Rio de Janeiro (UFRRJ). A solução permite o envio de conjuntos de dados em formato CSV acompanhados de metadados descritivos, o versionamento com preservação de estados anteriores, o controle de visibilidade entre público e privado e a colaboração por meio de grupos com papéis diferenciados. A plataforma também oferece prévia tabular dos arquivos e download individual ou em pacote. O trabalho demonstra a viabilidade de reunir, em um ambiente institucional, recursos de publicação, rastreabilidade e acesso controlado a dados acadêmicos, e sugere caminhos para aprimoramentos futuros, como suporte a novos formatos, disponibilização de API para consumo programático e avaliação de usabilidade com a comunidade universitária.

Palavras-chave: gestão de dados, repositório institucional, datasets, plataforma web, versionamento, UFRRJ.

ABSTRACT

DataRural: Um Repositório Institucional de Datasets para a UFRRJ

Rafael Vieira da Silva and Helcio Duarte Dantas

Setembro/2026

Advisor: Filipe Braida do Carmo, D.Sc.

Data management is essential for the continuity of research, outreach, and administrative activities in universities. However, datasets produced in these institutions often remain scattered across local files and unintegrated systems, lacking documentation, access control, and history preservation, which hinders their discovery, interpretation, and reuse. Addressing this problem, this work describes the development of DataRural, an institutional web platform created to centralize and organize the publication and sharing of datasets at the Universidade Federal Rural do Rio de Janeiro (UFRRJ). The solution enables uploading CSV datasets accompanied by descriptive metadata, versioning with preservation of previous states, visibility control between public and private, and collaboration through groups with distinct roles. The platform also offers tabular previews of files and individual or bundled downloads. This work demonstrates the feasibility of combining publication, traceability, and controlled access to academic data within an institutional environment, and suggests avenues for future enhancements, such as support for new formats, the provision of an API for programmatic consumption, and usability evaluation with the university community.

Keywords: *data management, institutional repository, datasets, web platform, versioning, UFRRJ.*

Lista de Figuras

Figura 3.1: Página inicial do Kaggle, com navegação para competições, busca e cadastro, além da apresentação dos públicos de desenvolvedores, organizações e pesquisadores.	16
Figura 3.2: Gerenciamento de membros de uma comunidade no Zenodo, com identificação dos participantes, papéis, visibilidade da participação e controles de convite e remoção.	17
Figura 3.3: Página inicial do Figshare, com busca e navegação pelo acervo, acesso à conta e destaque para o compartilhamento de resultados de pesquisa e as soluções para instituições e editoras.	19
Figura 3.4: Primeira interface do DataRural, com formulário de envio de CSV, identificação do dataset, versão e observações para o README. .	21
Figura 3.5: Recorte do mockup da página de detalhes de um dataset do DataRural, com dicionário de colunas, indicadores e informações dos responsáveis. Os dados exibidos são ilustrativos.	23
Figura 4.1: Estrutura de diretórios do monorepo do DataRural, com os módulos da aplicação web e os pacotes de componentes e configurações compartilhadas.	42
Figura 4.2: Página inicial do DataRural, com busca de datasets públicos, indicadores do acervo e catálogo organizado por áreas de conhecimento da UFRRJ.	47

Figura 4.3: Tela de autenticação do DataRural, com acesso por e-mail e senha ou conta Google para utilização das funcionalidades restritas a usuários autenticados.	48
Figura 4.4: Etapa 1 do assistente de publicação de datasets do DataRural: envio do arquivo CSV, identificação de sua estrutura e pré-visualização das primeiras linhas.	50
Figura 4.5: Etapa 2 do assistente de publicação de datasets do DataRural: preenchimento dos metadados que descrevem o conjunto de dados, seu vínculo institucional e sua abrangência temporal e espacial. . .	51
Figura 4.6: Etapa 3 do assistente de publicação de datasets do DataRural: revisão dos tipos e preenchimento das descrições das colunas do CSV para compor o dicionário de dados.	52
Figura 4.7: Etapa 4 do assistente de publicação de datasets do DataRural: seleção da licença de uso e definição da visibilidade pública ou privada do conjunto de dados.	53
Figura 4.8: Etapa 5 do assistente de publicação de datasets do DataRural: conferência das informações cadastradas e aceite da declaração de conformidade institucional antes de concluir a publicação.	54
Figura 4.9: Página de detalhes de um dataset no DataRural, com metadados, índice de usabilidade, dicionário de colunas e acesso às abas de visualização, arquivos e versões.	55
Figura 4.10: Painel <i>Meus datasets</i> do DataRural, com indicadores dos conjuntos de dados do usuário autenticado e controles de busca, filtragem e início de nova publicação.	57

Lista de Tabelas

3.1	Requisitos funcionais do DataRural: operações previstas para publicação, consulta e gestão de datasets, colaboração entre usuários e administração da plataforma.	26
3.2	Requisitos não funcionais do DataRural: critérios de segurança, compatibilidade, clareza da interface, rastreabilidade e organização do software.	27
3.3	Regras de negócio do DataRural: condições de publicação, licenciamento e acesso aos datasets e restrições que orientam o funcionamento da plataforma.	28
3.4	Estrutura da entidade <i>users</i> do DataRural, que armazena os dados de autenticação e perfil dos usuários e sua associação a um papel global.	31
3.5	Estrutura da entidade <i>roles</i> do DataRural, que define os papéis globais de acesso, distinguindo usuários comuns de administradores da plataforma.	32
3.6	Estrutura da entidade <i>groups</i> do DataRural, que registra os grupos colaborativos, suas finalidades e os usuários responsáveis por eles.	33
3.7	Estrutura da entidade <i>group_members</i> do DataRural, que associa usuários a grupos colaborativos e registra o papel de cada membro no respectivo grupo.	33

3.8	Estrutura da entidade <i>licenses</i> do DataRural, que registra as licen- ças associáveis aos datasets e suas condições de uso e redistribuição.	34
3.9	Estrutura da entidade <i>dataset_areas</i> do DataRural, que registra as áreas temáticas utilizadas na classificação dos conjuntos de dados.	35
3.10	Estrutura da entidade <i>datasets</i> do DataRural, que reúne os me- tadados descritivos e as associações de autoria, grupo e licença, além das configurações de visibilidade de cada conjunto de dados.	35
3.11	Estrutura da entidade <i>dataset_versions</i> do DataRural, que registra as versões de cada conjunto de dados e sua marcação de exclusão lógica, preservando o histórico.	37
3.12	Estrutura da entidade <i>dataset_version_files</i> do DataRural, que re- gistra os arquivos CSV de cada versão de um dataset, identificando o arquivo principal e a ordem de exibição.	37
3.13	Estrutura da entidade <i>dataset_likes</i> do DataRural, que registra as curtidas por meio da associação entre cada dataset e o usuário que o curtiu.	38
3.14	Estrutura da entidade <i>dataset_favorites</i> do DataRural, que associa usuários aos datasets salvos como favoritos para acesso pessoal rápido.	39
3.15	Estrutura da entidade <i>audits</i> do DataRural, que registra alterações nas entidades do sistema, incluindo a operação realizada, os valores alterados e a identificação do responsável.	39
4.1	Relação entre funcionalidades descritas na implementação do Da- taRural, requisitos funcionais da proposta e mecanismos utilizados para realizá-las.	59

Lista de Abreviaturas e Siglas

API	<i>application programming interface</i>
CSV	<i>comma-separated values</i>
CSRF	<i>cross-site request forgery</i>
FAIR	<i>findable, accessible, interoperable, reusable</i>
LGPD	Lei Geral de Proteção de Dados Pessoais
MVC	<i>model-view-controller</i>
NIST	<i>National Institute of Standards and Technology</i>
ODbL	<i>Open Database License</i>
ORM	<i>object-relational mapping</i>
RBAC	<i>role-based access control</i>
RDM	<i>research data management</i>
UFRRJ	Universidade Federal Rural do Rio de Janeiro

Sumário

Agradecimentos	i
Resumo	iii
Abstract	iv
Lista de Figuras	v
Lista de Tabelas	vii
Lista de Abreviaturas e Siglas	ix
1 Introdução	1
1.1 Objetivo	3
1.2 Uso de Inteligência Artificial	3
1.3 Organização do Trabalho	4
2 Gestão e Compartilhamento de Dados de Pesquisa	5
2.1 Dados de pesquisa, datasets e metadados	5
2.2 Gestão de dados de pesquisa	6
2.2.1 Desafios da gestão de dados	7

2.2.2	Privacidade, ética e dados sensíveis	8
2.3	Princípios FAIR	9
2.4	Dados abertos e licenciamento	10
2.5	Versionamento de dados	11
2.6	Plataformas de compartilhamento de dados	12
2.7	Formato CSV e dados tabulares	13
3	DataRural	14
3.1	Trabalhos relacionados	15
3.1.1	Kaggle	15
3.1.2	Zenodo	16
3.1.3	Figshare	18
3.2	Visão geral do sistema	19
3.3	Concepção da interface e prototipação	20
3.3.1	Primeira interface do projeto	21
3.3.2	Geração e revisão do protótipo	22
3.3.3	Discussão da proposta visual	24
3.3.4	Fluxos de uso previstos	24
3.4	Requisitos do sistema	25
3.4.1	Requisitos funcionais	25
3.4.2	Requisitos não funcionais	27
3.4.3	Regras de negócio	28
3.5	Controle de acesso	29

3.6	Modelagem de dados	30
3.6.1	Entidade <i>users</i>	31
3.6.2	Entidade <i>roles</i>	32
3.6.3	Entidade <i>groups</i>	33
3.6.4	Entidade <i>group_members</i>	33
3.6.5	Entidade <i>licenses</i>	34
3.6.6	Entidade <i>dataset_areas</i>	34
3.6.7	Entidade <i>datasets</i>	35
3.6.8	Entidade <i>dataset_versions</i>	36
3.6.9	Entidade <i>dataset_version_files</i>	37
3.6.10	Entidade <i>dataset_likes</i>	38
3.6.11	Entidade <i>dataset_favorites</i>	38
3.6.12	Entidade <i>audits</i>	39
4	Implementação	41
4.1	Arquitetura da aplicação	41
4.2	Decisões tecnológicas	43
4.2.1	Servidor: AdonisJS e TypeScript	43
4.2.2	Interface: React e Inertia.js	44
4.2.3	Persistência: PostgreSQL e Lucid ORM	45
4.2.4	Armazenamento de arquivos	45
4.2.5	Interface e componentes visuais	46
4.2.6	Ambiente de desenvolvimento	46

4.3	Funcionalidades implementadas e interfaces	46
4.3.1	Página inicial e consulta ao catálogo	47
4.3.2	Autenticação e controle de acesso	48
4.3.3	Publicação de datasets	49
4.3.4	Exploração e download dos dados	54
4.3.5	Gestão pessoal de datasets	56
4.3.6	Versionamento e manutenção do histórico	57
4.3.7	Colaboração por grupos	58
4.3.8	Administração e auditoria	58
4.4	Síntese da implementação e atendimento à proposta	59
5	Conclusão	61
5.1	Considerações finais	61
5.2	Limitações e trabalhos futuros	63
	Referências	65

Capítulo 1

Introdução

A produção de dados faz parte de diferentes atividades realizadas em uma universidade. Projetos de pesquisa, ações de extensão, experimentos, levantamentos de campo e procedimentos administrativos geram registros que podem apoiar novos estudos e decisões institucionais. Entretanto, a continuidade desse valor depende da forma como os arquivos são mantidos e disponibilizados. A gestão de dados ao longo de seu ciclo de vida envolve atividades como organização, documentação, armazenamento, preservação e compartilhamento (HIGGINS, 2008). Na ausência de práticas institucionais estruturadas, o acesso e a interpretação desses registros acabam condicionados ao conhecimento tácito de seus produtores originais.

Essa dependência cria dificuldades que ultrapassam o simples armazenamento. Mesmo quando um arquivo pode ser encontrado, nem sempre estão disponíveis informações suficientes para esclarecer sua origem, o período representado, a unidade responsável ou as condições de utilização. Os metadados fornecem esse contexto ao descrever características necessárias à localização, à interpretação e à administração dos dados (RILEY, 2017). Além disso, alterações realizadas diretamente sobre um mesmo documento podem apagar estados anteriores e dificultar a identificação do material utilizado em uma pesquisa. A preservação de versões permite reconhecer mudanças e indicar com maior precisão o estado do conjunto empregado em determinado resultado (KLUMP et al., 2021). Como consequência da ausência desses cuidados, dados potencialmente úteis podem permanecer inacessíveis, ser interpretados de

maneira incorreta ou exigir um novo processo de coleta.

O compartilhamento por meios genéricos também não atende, de forma integrada, às diferentes situações encontradas no ambiente acadêmico. Alguns conjuntos devem ser divulgados publicamente, enquanto outros precisam permanecer restritos durante determinada etapa do trabalho. A sigla FAIR corresponde aos termos *findable* (localizável), *accessible* (acessível), *interoperable* (interoperável) e *reusable* (reutilizável). Esses princípios orientam a descrição e a disponibilização de dados de forma a favorecer sua descoberta e reutilização (WILKINSON et al., 2016). Esses princípios não exigem que todos os dados sejam abertos: a acessibilidade pode envolver procedimentos de autenticação e autorização, desde que as condições de acesso estejam documentadas. Em atividades desenvolvidas por laboratórios, equipes ou unidades, ainda é necessário distinguir as responsabilidades de cada participante. Desse modo, uma solução institucional precisa conciliar descoberta, colaboração e controle, sem reduzir o conjunto de dados a um arquivo isolado de seu contexto.

Na Universidade Federal Rural do Rio de Janeiro (UFRRJ), a diversidade de áreas de atuação amplia a possibilidade de produção e reaproveitamento desses registros. Dados originados em diferentes setores podem interessar a pesquisadores, estudantes, gestores e ao público externo, desde que sejam apresentados de maneira organizada. Repositórios de dados contribuem para tornar os materiais de pesquisa mais visíveis e localizáveis, favorecendo sua reutilização (PAMPEL et al., 2013). Nesse contexto, este trabalho considera a necessidade de um ambiente próprio para reunir os conjuntos produzidos na instituição e apoiar a formação de um acervo que permaneça útil para além do projeto ou atividade que o originou.

Diante desse cenário, este trabalho apresenta o DataRural, uma plataforma web para a publicação e a gestão de datasets da UFRRJ. A solução busca estabelecer um ponto comum no qual os conjuntos possam ser descritos, consultados, atualizados e compartilhados conforme as permissões definidas por seus responsáveis. Ao reunir essas operações, o projeto procura reduzir a dispersão dos arquivos e favorecer a continuidade do uso dos dados produzidos na instituição.

1.1 Objetivo

O objetivo geral deste trabalho é projetar e desenvolver uma plataforma institucional de datasets para a UFRRJ, denominada DataRural, capaz de apoiar a publicação, a organização, a consulta e o compartilhamento de conjuntos de dados em formato CSV. A plataforma deve permitir que cada dataset seja acompanhado das informações necessárias à sua identificação e que seu acesso seja adequado tanto à divulgação pública quanto ao trabalho restrito de usuários e equipes.

Para alcançar esse objetivo, o sistema deve oferecer mecanismos de autenticação e autorização, possibilitar a formação de grupos com diferentes papéis e manter o histórico das atualizações realizadas nos datasets. Também deve fornecer recursos que auxiliem a descoberta e a inspeção do material publicado, como busca, classificação por área temática, apresentação de metadados, visualização prévia e download dos arquivos.

Além da disponibilização das funcionalidades, pretende-se estruturar a aplicação de maneira modular, separando as responsabilidades relacionadas à interface, às regras do sistema, à persistência das informações e ao armazenamento dos arquivos. Essa organização busca permitir a evolução gradual da plataforma e sua futura adaptação a novos formatos ou formas de integração institucional.

1.2 Uso de Inteligência Artificial

O desenvolvimento deste trabalho utilizou ferramentas baseadas em modelos de linguagem de grande escala (*large language models*) em diferentes etapas do processo. A presente seção registra essa utilização de forma transparente, em atendimento às boas práticas de integridade acadêmica.

Na escrita do texto, modelos de linguagem foram empregados como auxílio à redação, revisão de coesão e sugestão de reformulações. A responsabilidade pelo conteúdo, pelas decisões conceituais e pela verificação das informações permaneceu integralmente com os autores. Na busca de referências, as ferramentas auxiliaram na

identificação de termos, autores e publicações relacionadas ao tema, servindo como ponto de partida para consultas posteriores em bases acadêmicas.

No desenvolvimento do sistema, modelos de linguagem foram utilizados como apoio à geração de código, à resolução de dúvidas técnicas e à exploração de alternativas de implementação. Os trechos sugeridos foram avaliados, adaptados e integrados ao projeto conforme as decisões de arquitetura definidas pelos autores. Na concepção da interface, o Claude auxiliou na geração de um mockup a partir do minimundo do projeto, com análise e feedback dos autores para orientar seu refinamento. A Seção 3.3 apresenta esse processo e distingue a proposta visual das interfaces do sistema implementado.

1.3 Organização do Trabalho

Este trabalho está organizado da seguinte forma:

- Capítulo 2 (Gestão e Compartilhamento de Dados de Pesquisa): discute a problemática que motiva este trabalho, abordando os desafios da gestão de dados em instituições de pesquisa, os princípios FAIR, dados abertos e licenciamento, versionamento de dados, plataformas de compartilhamento e as particularidades do formato CSV;
- Capítulo 3 (DataRural): apresenta a proposta da plataforma, compara a solução com plataformas existentes, discute a concepção da interface por meio de um mockup e define os fluxos de uso previstos, os requisitos, o controle de acesso e a modelagem de dados;
- Capítulo 4 (Implementação): descreve a arquitetura adotada, justifica as decisões tecnológicas e apresenta as funcionalidades implementadas, suas interfaces e sua relação com os requisitos da proposta;
- Capítulo 5 (Conclusão): apresenta as considerações finais, as limitações identificadas e as possibilidades de continuidade e ampliação do trabalho.

Capítulo 2

Gestão e Compartilhamento de Dados de Pesquisa

Este capítulo discute a problemática que motiva a proposta do DataRural. A questão central é a gestão dos dados produzidos em atividades de pesquisa: como organizá-los, documentá-los, preservá-los e compartilhá-los de forma que permaneçam úteis para além do projeto ou da pessoa que os gerou. Para situar essa discussão, são apresentados os conceitos de dataset e metadados, os desafios enfrentados por instituições que produzem dados sem infraestrutura dedicada, os princípios que orientam boas práticas de disponibilização, as implicações do licenciamento e da privacidade, e o papel do versionamento na preservação do histórico. O capítulo também aborda os tipos de plataformas que procuram responder a esses desafios e as particularidades do formato CSV como veículo de dados tabulares.

2.1 Dados de pesquisa, datasets e metadados

Universidades produzem dados em diferentes contextos: experimentos de laboratório, levantamentos de campo, registros administrativos, indicadores acadêmicos e projetos de extensão. Esses registros podem apoiar novos estudos, subsidiar decisões institucionais ou servir como evidência para resultados publicados. Entretanto, a simples existência de um arquivo não garante que seu conteúdo será compreendido,

localizado ou reutilizado por outras pessoas.

Um *dataset*, ou conjunto de dados, é uma coleção organizada de registros relacionados. Em uma representação tabular, cada linha geralmente corresponde a uma observação e as colunas representam atributos. Quando um dataset é publicado sem informações sobre sua origem, finalidade, unidade responsável, período coberto ou procedimentos de coleta, o custo de interpretá-lo pode superar o custo de produzir novos dados. Esse problema é agravado quando os dados passam de uma pessoa para outra ou quando o responsável original não está mais disponível para esclarecer dúvidas.

Essas informações complementares são denominadas metadados. São dados que descrevem outros dados e oferecem elementos para sua localização, interpretação, administração e reutilização (RILEY, 2017). Metadados descritivos incluem título, autoria, resumo e palavras-chave; metadados administrativos registram licença, responsável e condições de acesso; e metadados estruturais informam como os arquivos, tabelas e variáveis se relacionam (RILEY, 2017). A ausência de qualquer dessas camadas pode tornar um conjunto tecnicamente acessível, mas praticamente inutilizável.

2.2 Gestão de dados de pesquisa

A gestão de dados de pesquisa, conhecida como *research data management* (RDM), reúne as práticas aplicadas ao longo do ciclo de vida dos dados produzidos em atividades de investigação (HIGGINS, 2008). Esse ciclo inclui planejamento, coleta, organização, documentação, armazenamento, controle de acesso, preservação, compartilhamento e, eventualmente, descarte. Uma gestão adequada reduz a dependência do conhecimento individual de quem produziu os arquivos e aumenta a possibilidade de utilização futura por outras pessoas.

A discussão sobre gestão e compartilhamento envolve tanto as possibilidades de reutilização quanto os incentivos e as responsabilidades dos produtores dos dados. Borgman (2012) distingue motivações como a verificação de pesquisas, o acesso aos

resultados do financiamento público, a formulação de novas perguntas e o avanço científico. Essas finalidades não pressupõem práticas idênticas entre as disciplinas, mas evidenciam a necessidade de preservar o contexto dos registros e de explicitar as condições de compartilhamento.

2.2.1 Desafios da gestão de dados

Apesar do reconhecimento crescente, a gestão de dados enfrenta desafios práticos que dificultam sua adoção. Em um estudo de dez anos no *Center for Embedded Networked Sensing*, Wallis, Rolando e Borgman (2013) observaram que o compartilhamento ocorria principalmente por trocas interpessoais e dependia de condições como o reconhecimento dos produtores e a prioridade de publicação. Embora os resultados se refiram ao centro estudado, eles ajudam a compreender por que disponibilizar infraestrutura não basta para estabelecer práticas de compartilhamento.

O primeiro desafio é a fragmentação. Os dados permanecem distribuídos entre computadores pessoais, pastas compartilhadas, serviços de armazenamento em nuvem e sistemas internos sem integração. Quando um pesquisador se aposenta, muda de instituição ou simplesmente conclui um projeto, os arquivos produzidos podem tornar-se inacessíveis ou incompreensíveis para outras pessoas. A continuidade do valor dos dados depende de registros que não se percam junto com a memória individual de seus produtores.

O segundo desafio é a perda de contexto. Mesmo quando um arquivo pode ser localizado, nem sempre estão disponíveis informações suficientes para esclarecer sua origem, o período representado, a unidade responsável ou as condições de utilização. Sem metadados adequados, dois pesquisadores podem utilizar o mesmo arquivo e produzir interpretações divergentes sem perceber que estão tratando de versões diferentes ou de recortes distintos dos mesmos dados.

O terceiro desafio é a reprodutibilidade. Alterações realizadas diretamente sobre um mesmo documento podem apagar estados anteriores e impedir a verificação de análises passadas. Se não existe um mecanismo que preserve cada estado do conjunto, torna-se impossível determinar qual material sustentou um resultado previamente

publicado (KLUMP et al., 2021).

O quarto desafio envolve as barreiras à reutilização. Um dataset pode estar acessível publicamente e, ainda assim, não conter informações suficientes sobre o método de coleta, as unidades de medida, os valores ausentes ou as limitações conhecidas. Nesses casos, o esforço para compreender e validar os dados pode anular a vantagem do compartilhamento.

Os problemas discutidos na literatura orientam a análise das necessidades do DataRural, mas não constituem, por si só, um diagnóstico empírico da UFRRJ. Neste trabalho, a fragmentação, a perda de contexto e as barreiras à reutilização são tomadas como riscos a enfrentar na concepção de uma plataforma institucional. A proposta procura reduzir a dependência de arquivos dispersos e de esclarecimentos individuais, reunindo publicação, documentação e controle de acesso.

2.2.2 Privacidade, ética e dados sensíveis

Nem todos os dados produzidos em atividades de pesquisa podem ou devem ser disponibilizados livremente. Pesquisas que envolvem dados pessoais, informações de saúde, registros administrativos ou materiais protegidos por sigilo institucional exigem cuidados específicos que antecedem qualquer decisão de publicação.

No Brasil, a Lei Geral de Proteção de Dados Pessoais (LGPD, Lei nº 13.709/2018) estabelece regras para o tratamento de dados pessoais, incluindo a coleta, o armazenamento e o compartilhamento dessas informações (Brasil, 2018). A lei exige que o tratamento observe princípios como finalidade, adequação, necessidade e transparência. Pesquisas acadêmicas possuem previsões específicas, mas não estão isentas das obrigações de proteção.

Além das exigências legais, existem questões éticas. Dados de populações vulneráveis, comunidades tradicionais ou grupos sub-representados podem conter vieses que, se não forem documentados, podem levar à perpetuação de desigualdades em análises derivadas. A documentação das características e limitações dos dados contribui para que seus reutilizadores avaliem a adequação do material ao contexto pretendido.

Essas restrições tornam evidente que uma plataforma de gestão de dados não pode se limitar à publicação aberta. É necessário que o responsável possa definir o nível de acesso de cada conjunto e que o sistema ofereça mecanismos para que essas condições sejam respeitadas. A abertura total não é desejável em todos os casos, e a restrição de acesso não deve ser confundida com falta de transparência.

2.3 Princípios FAIR

Diante dos desafios apresentados na seção anterior, foram propostos princípios que orientam a descrição e a disponibilização de dados de forma a favorecer sua descoberta, acesso e reutilização. Os princípios FAIR, publicados por Wilkinson et al. (2016), estabelecem que dados e outros objetos digitais devem ser:

- Localizáveis (*findable*): os dados devem ser descritos com metadados ricos e receber identificadores persistentes que facilitem sua descoberta por pessoas e por sistemas computacionais;
- Acessíveis (*accessible*): uma vez localizados, deve existir um procedimento claro para recuperar os dados, ainda que esse procedimento envolva autenticação ou autorização;
- Interoperáveis (*interoperable*): os dados e seus metadados devem utilizar vocabulários e formatos que permitam a interpretação e o cruzamento com outros conjuntos;
- Reutilizáveis (*reusable*): os dados devem ser acompanhados de informações de proveniência, licença e contexto suficientes para que terceiros possam avaliá-los e utilizá-los de forma apropriada.

É importante observar que os princípios FAIR não exigem que todos os dados sejam abertos. A acessibilidade prevista pelo segundo princípio reconhece que o acesso pode depender de procedimentos de autenticação e autorização (WILKINSON et al., 2016). Um dataset pode seguir os princípios FAIR e, ainda assim, ter acesso restrito a um grupo de pesquisa ou a usuários autorizados. O que se espera é que as condições de acesso estejam documentadas e que exista um caminho definido para

solicitá-lo.

A rastreabilidade complementa os princípios FAIR ao permitir identificar a origem e o histórico de um dado, incluindo as transformações ou versões pelas quais passou. Sem essa informação, duas análises que utilizam arquivos com o mesmo nome podem produzir resultados diferentes sem que a causa seja facilmente identificada.

2.4 Dados abertos e licenciamento

A reutilização de dados depende não apenas de sua disponibilidade técnica, mas também da clareza das condições de uso. Ao analisar 56 recursos de dados científicos no contexto biomédico, Carbon et al. (2019) identificaram barreiras decorrentes de licenças ausentes, restritivas ou incompatíveis. O estudo distingue o acesso aos dados da possibilidade de reutilizá-los e redistribuí-los. Para o DataRural, essa distinção fundamenta a necessidade de apresentar as condições de uso junto aos metadados, sem tratar o acesso público como autorização irrestrita.

O uso de instrumentos padronizados pode reduzir ambiguidades, embora não elimine todas as restrições à reutilização (CARBON et al., 2019). As licenças CC BY e CC BY-SA estabelecem condições de atribuição e, no segundo caso, de compartilhamento das adaptações sob a mesma licença (Creative Commons, s.d.a). O CC0 é um instrumento de dedicação ao domínio público, e não uma licença de atribuição (Creative Commons, s.d.b). A Open Database License (ODbL), por sua vez, estabelece condições para o uso e o compartilhamento de bases de dados (Open Data Commons, s.d.). A escolha de um instrumento deve considerar os direitos sobre o material e não afasta cuidados com privacidade ou sigilo.

Assim, abertura e controle de acesso não são conceitos incompatíveis. Uma mesma plataforma pode reunir conjuntos abertos, conjuntos públicos com condições específicas e conjuntos privados destinados a uma equipe. O aspecto central é que o nível de acesso e as condições de reutilização sejam apresentados de maneira explícita, evitando a ambiguidade que dificulta o reaproveitamento.

2.5 Versionamento de dados

Datasets de pesquisa são frequentemente objetos em evolução. Novos registros podem ser adicionados à medida que a coleta avança, correções podem alterar valores previamente publicados e recodificações podem modificar a estrutura das variáveis. Quando essas mudanças são aplicadas diretamente sobre o mesmo arquivo, sem preservar os estados anteriores, torna-se impossível determinar qual versão dos dados sustentou um resultado previamente divulgado.

O versionamento responde a esse problema ao preservar estados sucessivos de um recurso ao longo do tempo. Em vez de substituir definitivamente um arquivo a cada alteração, o sistema cria uma nova versão e mantém a relação com as anteriores. Essa abordagem permite recuperar estados passados e informar com precisão qual versão foi utilizada em determinada análise.

A identificação precisa das versões permite relacionar os dados aos resultados que deles derivam. Klump et al. (2021), a partir da análise de práticas de 33 organizações, propõem princípios que distinguem revisão, publicação de versões, granularidade, manifestação, proveniência e citação. Essa abordagem evidencia que registrar apenas um número de versão é insuficiente: também é necessário documentar a natureza das alterações e manter relações que permitam identificar o material utilizado em uma análise.

O versionamento de dados também exige decisões de armazenamento diferentes das adotadas para código-fonte. Hoyt e Gyori (2024) observam que sistemas de controle de versão são otimizados para arquivos textuais e podem ser inadequados para arquivos muito grandes ou binários. Os autores apontam repositórios de dados como alternativas para armazenar e compartilhar esses materiais. No DataRural, a preservação dos arquivos de cada versão é a estratégia escolhida para manter estados anteriores dos conjuntos, sem depender da reconstrução por diferenças entre linhas.

2.6 Plataformas de compartilhamento de dados

Os desafios descritos nas seções anteriores motivaram o desenvolvimento de plataformas que procuram apoiar diferentes etapas da gestão de dados. Essas plataformas assumem formatos distintos de acordo com o público atendido e a finalidade dos conjuntos publicados.

Pampel et al. (2013) discutem a diversidade dos repositórios de dados de pesquisa e apresentam o registro re3data.org como instrumento para sua descoberta. A descrição dessas infraestruturas envolve aspectos como escopo, acesso, licenças e identificadores persistentes. Para o presente trabalho, esses aspectos oferecem critérios de comparação mais precisos do que a simples presença de armazenamento e download.

A literatura também distingue repositórios de propósito geral de sistemas especializados em determinados domínios. Em uma análise voltada a dados de pesquisa matemática, Conrad et al. (2024) incluem Zenodo e Figshare entre as soluções de propósito geral e discutem recursos como identificação persistente e preservação. Essa distinção ajuda a situar o DataRural: seu recorte é institucional, enquanto as plataformas relacionadas atendem comunidades mais amplas. Independentemente do recorte, autoria, licença, versão, descrição e condições de acesso devem acompanhar o arquivo publicado.

A existência dessas plataformas não resolve, por si só, todos os problemas da gestão de dados. A qualidade dos metadados, a adesão dos pesquisadores e a manutenção institucional continuam sendo fatores determinantes. Ainda assim, uma solução tecnológica que centralize a publicação, a documentação e o controle de acesso pode reduzir a fragmentação e oferecer um ponto de referência para os dados produzidos em uma instituição. A análise detalhada de plataformas existentes é apresentada na seção de trabalhos relacionados do Capítulo 3.

2.7 Formato CSV e dados tabulares

O formato CSV (*comma-separated values*) é amplamente utilizado como veículo de dados tabulares por sua simplicidade e compatibilidade (SHAFRANOVICH, 2005). Entretanto, essa mesma simplicidade introduz problemas relevantes para a gestão de dados.

O CSV não define obrigatoriamente os tipos das colunas, não mantém relacionamentos entre tabelas e não possui um esquema embutido capaz de descrever cada variável (TENNISON; KELLOGG; HERMAN, 2015). Datas, números decimais, valores ausentes, delimitadores e codificações de caracteres podem ser interpretados de formas diferentes por aplicações distintas. Dois arquivos identificados como CSV podem exigir configurações completamente diferentes durante a importação.

Essas limitações tornam os metadados especialmente importantes quando o CSV é o formato adotado. O nome de uma coluna nem sempre explica sua unidade de medida, os valores permitidos ou o procedimento utilizado na coleta. Um arquivo pode ser amplamente compatível do ponto de vista técnico, mas sua reutilização efetiva depende de documentação externa e de convenções consistentes. Sem essa documentação, a simplicidade do formato torna-se uma armadilha: o dado é acessível, mas não compreensível.

Uma prévia tabular apresenta as primeiras linhas e colunas de um arquivo antes do download completo. Essa visualização auxilia a inspeção rápida e permite reconhecer a estrutura do conjunto. Esse recurso, entretanto, não substitui uma análise de qualidade, uma vez que problemas podem existir em linhas não apresentadas ou depender do significado científico dos valores.

Capítulo 3

DataRural

A gestão de dados tornou-se uma dimensão cada vez mais relevante para universidades, sobretudo em instituições que produzem informações acadêmicas, administrativas e experimentais em diferentes setores. Ainda assim, é comum que esses dados permaneçam distribuídos em arquivos locais, planilhas compartilhadas informalmente, sistemas internos pouco integrados ou repositórios que não oferecem documentação suficiente para sua interpretação posterior. Quando isso ocorre, o valor dos dados diminui com o tempo, pois sua reutilização passa a depender do conhecimento individual de quem os produziu ou armazenou.

No contexto da UFRRJ, esse problema pode afetar tanto atividades de pesquisa quanto ações de gestão institucional. Dados de experimentos, levantamentos, projetos de extensão, indicadores acadêmicos ou registros administrativos podem ter utilidade para diferentes públicos, desde que estejam descritos, licenciados e organizados de maneira compreensível. Assim, a simples existência de arquivos digitais não garante transparência, reprodutibilidade ou reaproveitamento científico. É necessário oferecer um ambiente que trate o conjunto de dados como um artefato institucional, com autoria, histórico, permissões e condições claras de uso.

Com base nessa necessidade, este trabalho propõe a Plataforma Institucional de Datasets da UFRRJ, chamada neste projeto de *DataRural*. A proposta consiste em uma aplicação web voltada à publicação, consulta, atualização e organização de

datasets institucionais, tendo o formato CSV como ponto de partida. A escolha por esse formato se justifica por sua simplicidade, ampla adoção e compatibilidade com ferramentas de análise de dados, sem impedir que a plataforma evolua futuramente para outros formatos ou para integrações diretas com bases de dados.

O DataRural parte de referências conhecidas no ecossistema de dados, como Kaggle, portais de dados abertos e repositórios científicos. No entanto, seu foco não é reproduzir integralmente nenhuma dessas soluções. A intenção é adaptar conceitos consolidados, como publicação de datasets, hierarquia de usuários e licenciamento, para uma realidade universitária específica. Dessa forma, a plataforma busca apoiar tanto a divulgação pública de dados quanto o trabalho colaborativo de grupos, laboratórios e unidades acadêmicas.

3.1 Trabalhos relacionados

Antes da definição das funcionalidades do DataRural, foram observadas plataformas voltadas ao compartilhamento, à preservação ou à exploração de dados. A análise a seguir combina estudos publicados e observação das interfaces, distinguindo as contribuições da literatura dos elementos visíveis nas capturas de tela. Kaggle, Zenodo e Figshare são discutidos como referências para a concepção do projeto, e não como soluções submetidas a uma avaliação experimental neste trabalho.

3.1.1 Kaggle

O Kaggle reúne datasets, competições e notebooks utilizados em atividades de ciência de dados. Sua dimensão colaborativa é examinada por Quaranta, Calefato e Lanubile (2022), que analisaram 1.380 notebooks da plataforma em um estudo sobre boas práticas de colaboração. Os autores identificaram diferenças entre o conhecimento das práticas e sua adoção, destacando a importância da documentação e do suporte oferecido pelas ferramentas. Para o DataRural, essa discussão reforça que disponibilizar dados deve ser acompanhado de informações que permitam compreendê-los e reutilizá-los.

A Figura 3.1 apresenta a página inicial do Kaggle¹, com acesso à busca, às competições e ao cadastro, além de uma apresentação dos públicos atendidos. Na captura, a plataforma destaca desenvolvedores de inteligência artificial, organizações e pesquisadores. Essa organização visual contextualiza sua orientação comunitária e a articulação entre dados, desafios e atividades de aprendizagem, que serviram de referência para a concepção do DataRural.




Figura 3.1: Página inicial do Kaggle, com navegação para competições, busca e cadastro, além da apresentação dos públicos de desenvolvedores, organizações e pesquisadores.

O aspecto do Kaggle tomado como referência neste trabalho é a articulação entre dados e materiais de análise compartilhados. O DataRural adota um recorte distinto: concentra-se na publicação e na gestão de datasets vinculados à UFRRJ, sem propor competições ou um ambiente de execução de notebooks. A diferença de escopo não implica ausência de colaboração ou de controle de acesso no Kaggle, mas delimita quais conceitos são aproveitados na solução institucional proposta.

3.1.2 Zenodo

O Zenodo é um repositório de propósito geral para divulgação de produtos de pesquisa. Conrad et al. (2024) o incluem entre as infraestruturas multidisciplinares

¹Disponível em: <<https://www.kaggle.com/>>. Acesso em: 14 set. 2026.

que apoiam o compartilhamento e a identificação persistente de recursos. Para o DataRural, essa referência destaca a importância de tratar o conjunto de dados como um produto documentado e citável, com autoria e informações que favoreçam sua reutilização.

Além da publicação de artefatos, o Zenodo oferece recursos de organização por comunidades. A Figura 3.2 apresenta a tela de gerenciamento de membros da comunidade *Biodiversity Literature Repository*, utilizada como exemplo na documentação oficial da plataforma². A interface reúne busca e filtros, opções de convite e remoção de participantes e a indicação do papel de cada membro. A visibilidade exibida nessa tela diz respeito à participação do membro na comunidade, não à visibilidade de um dataset.




Figura 3.2: Gerenciamento de membros de uma comunidade no Zenodo, com identificação dos participantes, papéis, visibilidade da participação e controles de convite e remoção.

Esse exemplo evidencia que a colaboração e a diferenciação de responsabilidades também fazem parte do Zenodo. Para o DataRural, a referência contribui para discutir a organização de equipes e o controle das operações sobre conjuntos compartilhados. A proposta deste trabalho não se diferencia pela simples existência de grupos ou

²Disponível em: <<https://help.zenodo.org/docs/communities/manage-members/>>. Acesso em: 14 set. 2026.

papéis, mas pela concepção de uma aplicação própria voltada ao contexto da UFRRJ, na qual os fluxos de publicação, os metadados e as regras de acesso são definidos em função do escopo institucional do projeto.

3.1.3 Figshare

O Figshare também integra o conjunto de repositórios de propósito geral discutido por Conrad et al. (2024). O estudo registra seu uso como base tecnológica do repositório 4TU.ResearchData, evidenciando que uma infraestrutura geral pode sustentar serviços voltados a uma comunidade específica. Essa experiência é pertinente ao DataRural por aproximar o compartilhamento de produtos acadêmicos das necessidades de organização institucional.

A Figura 3.3 apresenta uma captura da página inicial do Figshare³. Na parte superior, a interface reúne navegação pelo acervo, busca, autenticação e cadastro. A área central destaca o armazenamento, o compartilhamento e a descoberta de resultados de pesquisa, além de indicar soluções destinadas a instituições e editoras. Para a concepção do DataRural, essa apresentação contribui como referência para reunir, na entrada da plataforma, os caminhos de consulta ao acervo e de participação dos usuários.

³Disponível em: <<https://figshare.com/>>. Acesso em: 14 set. 2026.




Figura 3.3: Página inicial do Figshare, com busca e navegação pelo acervo, acesso à conta e destaque para o compartilhamento de resultados de pesquisa e as soluções para instituições e editoras.

A indicação de soluções institucionais na própria página reforça que o atendimento a universidades não é uma característica exclusiva do DataRural. A contribuição pretendida neste trabalho está na concepção de uma aplicação própria para a UFRRJ, com metadados, organização de grupos e regras de acesso definidos para o contexto do projeto. Assim, o Figshare serve como referência para a divulgação de produtos acadêmicos, enquanto o DataRural explora a articulação dessas práticas com as necessidades locais de gestão e colaboração.

3.2 Visão geral do sistema

O DataRural é uma aplicação web que centraliza a publicação, consulta e gestão de datasets institucionais. A plataforma foi concebida para atender a dois perfis principais de usuário: o usuário comum, que publica e reutiliza dados, e o administrador, responsável pela manutenção da plataforma, gerenciamento de usuários e configuração de áreas temáticas. Alguns recursos, como a consulta e o download de datasets públicos, estão disponíveis mesmo para usuários não autenticados, ampliando o alcance da informação.

A unidade central do sistema é o dataset. Cada conjunto de dados é descrito por metadados como título, descrição, área temática, unidade responsável, região, período, palavras-chave e licença. Essas informações fornecem o contexto necessário para sua compreensão e reutilização. A visibilidade controla o acesso: datasets públicos são acessíveis a qualquer visitante, enquanto datasets privados ficam restritos ao proprietário ou ao grupo ao qual estão vinculados.

O sistema adota o versionamento como princípio estrutural. Cada atualização de um conjunto de dados gera uma nova versão, preservando o histórico completo de modificações e permitindo rastrear qual versão foi utilizada em determinada análise ou relatório. Versões podem ser excluídas de forma lógica e restauradas quando necessário.

Os grupos colaborativos constituem outro elemento central da plataforma. Eles representam laboratórios, equipes ou unidades institucionais e permitem que múltiplos usuários trabalhem de forma coordenada sobre os mesmos datasets, com papéis bem definidos: dono, administrador, editor e leitor. Essa estrutura de colaboração diferencia o DataRural de repositórios de uso individual, tornando-o adequado tanto para a divulgação pública de dados quanto para o trabalho interno de equipes acadêmicas.

3.3 Concepção da interface e prototipação

A evolução da interface do DataRural é apresentada a partir de dois registros distintos: a primeira interface do projeto, centrada no envio de arquivos CSV, e um *mockup* elaborado com auxílio do Claude para explorar a organização das informações e os caminhos de navegação. A primeira registra uma versão inicial do sistema; o segundo representa uma proposta visual, cujos elementos não correspondem necessariamente às funcionalidades implementadas. Essa distinção permite contextualizar as escolhas de interface e sua relação com a solução descrita no Capítulo 4.

3.3.1 Primeira interface do projeto

A Figura 3.4 apresenta a primeira interface do DataRural, com um formulário de envio de conjuntos de dados. A tela reúne campos para o nome do dataset, a versão, a seleção de um arquivo CSV e observações destinadas ao README.md, além de um botão de acesso ao visualizador. A identidade visual ainda mantém a identificação do *Starter Kit* do AdonisJS, diferentemente das telas da plataforma apresentadas no capítulo de implementação.

A imagem mostra a interface web do DataRural. No topo, há uma barra de navegação com o logotipo 'Starter Kit' e o nome 'AdonisJS'. À esquerda, um menu lateral contém links para 'Dashboard', 'Administração' e 'Usuários'. O conteúdo principal, sob o título 'Conjunto de dados', apresenta o formulário 'Enviar conjunto de dados'. Este formulário inclui: um subtítulo explicando o processo de envio; campos de entrada para 'Nome do dataset' (contendo 'dataset X') e 'Versão' (contendo 'V1'); um botão 'Browse...' para selecionar o 'Arquivo CSV', com o texto 'No file selected.'; um campo de texto para 'Observações do README' com o placeholder 'Notas curtas que serão gravadas em README.md'; e um botão 'Salvar dataset'. Uma mensagem de feedback no rodapé do formulário indica que os nomes devem ser únicos e que o arquivo será armazenado no storage/datasets.

Figura 3.4: Primeira interface do DataRural, com formulário de envio de CSV, identificação do dataset, versão e observações para o README.

Nesse registro, o envio do arquivo e sua identificação estão concentrados em um único formulário, e a documentação aparece como um campo de observações livres. Na versão apresentada na Seção 4.3.3, a publicação é organizada em cinco etapas, com espaços específicos para metadados, dicionário de dados, licença e visibilidade. O contraste documenta a ampliação das informações solicitadas e a mudança na organização do fluxo, sem constituir, por si só, evidência de melhoria de usabilidade.

A concepção da interface também incluiu a exploração da experiência de consulta aos conjuntos publicados. O mockup discutido a seguir aborda essa dimensão: em vez de representar outra versão do formulário de envio, apresenta uma proposta para a página de detalhes de um dataset, destacando sua documentação e as informações

necessárias à reutilização.

3.3.2 Geração e revisão do protótipo

O mockup foi gerado com auxílio do Claude a partir do minimundo do projeto, entendido como a descrição do contexto institucional, dos usuários, das entidades e das regras que delimitam o sistema. Esse contexto reúne as necessidades de publicação de arquivos CSV, descrição dos conjuntos, consulta pública, colaboração por grupos e preservação do histórico. Sua utilização como entrada para a geração visual buscou aproximar a proposta de interface das necessidades do DataRural, e não apenas produzir uma composição gráfica genérica.

A geração foi acompanhada pela participação dos autores na análise da proposta e no fornecimento de feedback para seu refinamento. Essa participação caracteriza a revisão humana no processo, também denominada *human in the loop*: a ferramenta auxilia na elaboração visual, enquanto a avaliação da adequação ao minimundo e as decisões sobre o que incorporar ao projeto permanecem sob responsabilidade dos autores. Trata-se de uma atividade de concepção, e não de uma avaliação de usabilidade com usuários da universidade.

A Figura 3.5 apresenta um recorte do protótipo da página de detalhes de um dataset. A imagem registra uma proposta de organização da interface, não uma captura do sistema em funcionamento. Os nomes, valores, gráficos e contagens exibidos têm função ilustrativa e não representam resultados de testes nem indicadores de utilização do DataRural.




Figura 3.5: Recorte do mockup da página de detalhes de um dataset do DataRural, com dicionário de colunas, indicadores e informações dos responsáveis. Os dados exibidos são ilustrativos.

3.3.3 Discussão da proposta visual

No protótipo, o dicionário de colunas ocupa a região central, associando nomes de variáveis a descrições, tipos, unidades de medida e representações resumidas dos valores. Essa disposição dá destaque à interpretação dos dados: antes de obter o arquivo, o visitante deve encontrar informações que o ajudem a reconhecer o conteúdo e a avaliar sua adequação ao uso pretendido. A composição visual expressa, portanto, a preocupação com a documentação por atributo, complementar aos metadados gerais do conjunto.

A coluna lateral agrupa informações sobre mantenedores, palavras-chave, atividade e citação. A presença desses elementos permite discutir diferentes dimensões da publicação: a identificação dos responsáveis, a localização por tema, as formas de referência ao conjunto e o acompanhamento das interações. Já a organização em abas separa a visão geral de áreas destinadas à visualização e aos arquivos. Esses elementos funcionam como referências para a organização da experiência de consulta, sem que sua presença no mockup comprove a implementação dos mecanismos correspondentes.

O protótipo também apresenta abas de *notebooks* e discussão, que não são apresentadas como funcionalidades implementadas neste trabalho. A distinção evidencia que a exploração visual contemplou possibilidades mais amplas do que a entrega descrita no Capítulo 4. A solução desenvolvida prioriza publicação e consulta de CSV, metadados, controle de acesso, grupos e histórico de versões. Na página de detalhes implementada, apresentada na Seção 4.3.4, a navegação reúne visão geral, visualizador, arquivos e versões. Assim, o mockup é tratado como apoio à concepção, e não como uma especificação de que todos os elementos ilustrados seriam entregues nesta etapa.

3.3.4 Fluxos de uso previstos

A proposta organiza o uso da plataforma em três fluxos complementares: descoberta de dados, publicação e manutenção do acervo. Essa organização relaciona as

necessidades dos usuários aos requisitos apresentados na seção seguinte, sem vincular sua descrição a uma tela específica.

No fluxo de descoberta, o visitante deve poder localizar datasets públicos, consultar seus metadados e obter os arquivos de interesse. A busca e a classificação por área temática devem facilitar a seleção dos conjuntos, enquanto a apresentação da licença e de uma prévia tabular deve apoiar a avaliação inicial do material antes de sua reutilização.

O fluxo de publicação deve reunir o envio dos arquivos, a descrição do conjunto e a definição das condições de uso e de acesso. A identificação do responsável permite associar a publicação a um usuário e, quando necessário, a um grupo. A manutenção do acervo deve permitir atualizar os dados sem perder suas versões anteriores, além de controlar alterações de visibilidade e operações de exclusão conforme as permissões atribuídas.

Esses fluxos orientam a concepção da plataforma. As interfaces do sistema desenvolvido e os mecanismos utilizados para realizá-los são apresentados na Seção 4.3 do Capítulo 4, distinguindo a definição da proposta da apresentação de sua implementação.

3.4 Requisitos do sistema

Os requisitos apresentados nesta seção organizam as capacidades esperadas para a plataforma. Eles foram definidos a partir dos objetivos do projeto e procuram traduzir, em funcionalidades e restrições, a proposta de uma solução institucional para publicação e gestão de datasets. Para facilitar a leitura, os requisitos foram separados em funcionais, não funcionais e regras de negócio.

3.4.1 Requisitos funcionais

A Tabela 3.1 apresenta os requisitos funcionais definidos para o DataRural. Esses requisitos descrevem as operações que a plataforma deve disponibilizar aos seus

usuários, incluindo publicação, consulta, versionamento, colaboração e administração.

Tabela 3.1: Requisitos funcionais do DataRural: operações previstas para publicação, consulta e gestão de datasets, colaboração entre usuários e administração da plataforma.

Código	Descrição
RF-01	Permitir o upload de <i>datasets</i> em formato CSV.
RF-02	Permitir o upload de múltiplos arquivos CSV por versão do dataset.
RF-03	Permitir a criação de grupos de usuários com papéis (dono, admin, editor, visualizador).
RF-04	Permitir a criação de <i>datasets</i> privados.
RF-05	Permitir alternar a visibilidade (público/privado) de um dataset.
RF-06	Permitir o versionamento de <i>datasets</i> .
RF-07	Permitir a restauração de versões anteriores de um dataset.
RF-08	Permitir a exclusão lógica (<i>soft delete</i>) de versões.
RF-09	Permitir a descrição e o licenciamento de <i>datasets</i> publicados.
RF-10	Permitir a classificação de datasets por metadados (área, unidade, período, região, tags).
RF-11	Permitir o download individual de arquivos de um dataset.
RF-12	Permitir o download de todos os arquivos de uma versão em formato ZIP.
RF-13	Permitir o registro e autenticação de usuários.
RF-14	Permitir a edição de perfil do usuário (nome, bio, avatar, instituição, localização).
RF-15	Permitir que usuários curtam datasets.
RF-16	Permitir que usuários favoritem datasets para acesso rápido.
RF-17	Permitir a exploração e busca de datasets com filtro por área temática.

Código	Descrição
RF-18	Exibir uma prévia das primeiras linhas dos arquivos CSV de um dataset.
RF-19	Permitir a atribuição de datasets a grupos.
RF-20	Permitir a exclusão de datasets apenas pelo proprietário ou membro autorizado do grupo.
RF-21	Oferecer um painel administrativo para gestão de usuários e áreas temáticas.
RF-22	Registrar trilha de auditoria para alterações nas entidades principais.
RF-23	Oferecer suporte a internacionalização (i18n).
RF-24	Exibir perfis públicos de usuários.

3.4.2 Requisitos não funcionais

Os requisitos não funcionais, apresentados na Tabela 3.2, estabelecem restrições e qualidades esperadas para a plataforma. Eles orientam decisões de implementação relacionadas a segurança, organização do código, preservação do histórico e compatibilidade.

Tabela 3.2: Requisitos não funcionais do DataRural: critérios de segurança, compatibilidade, clareza da interface, rastreabilidade e organização do software.

Código	Descrição
RNF-01	A solução deve ser disponibilizada como aplicação web responsiva e compatível com navegadores atuais.
RNF-02	As senhas devem ser armazenadas por meio de representação criptográfica segura.
RNF-03	O acesso a rotas protegidas deve ser controlado por <i>middleware</i> de autenticação.

Código	Descrição
RNF-04	Os arquivos enviados devem ser validados, considerando inicialmente apenas o formato CSV.
RNF-05	O código deve manter separação entre interface, regras de negócio, persistência e armazenamento de arquivos.
RNF-06	A estrutura da plataforma deve permitir evolução para novos formatos e novas fontes de dados.
RNF-07	O histórico de versões deve ser preservado para manter rastreabilidade das alterações.
RNF-08	A interface deve apresentar metadados, permissões e licenças de forma clara ao usuário.
RNF-09	As principais entidades devem ser auditáveis.
RNF-10	A organização modular do sistema deve favorecer manutenção e expansão gradual.

3.4.3 Regras de negócio

As regras de negócio, listadas na Tabela 3.3, definem condições que devem ser respeitadas pela plataforma independentemente da tecnologia adotada. Elas delimitam permissões, restrições de formato e políticas de visibilidade que orientam o comportamento esperado do sistema.

Tabela 3.3: Regras de negócio do DataRural: condições de publicação, licenciamento e acesso aos datasets e restrições que orientam o funcionamento da plataforma.

Código	Descrição
RN-01	A publicação de <i>datasets</i> é restrita a usuários autenticados.
RN-02	Usuários não registrados podem visualizar e fazer download de <i>datasets</i> públicos.
RN-03	Todo <i>dataset</i> publicado deve possuir uma licença associada.

Código	Descrição
RN-04	<i>Datasets</i> não publicados são visíveis apenas pelo usuário proprietário ou membros do grupo associado.
RN-05	Nomes de <i>datasets</i> devem ser únicos no sistema.
RN-06	Cada arquivo CSV enviado deve ter no máximo 25 MB.
RN-07	Membros de grupo com papel de dono, admin ou editor podem editar <i>datasets</i> do grupo.
RN-08	Apenas membros com papel de dono ou admin podem excluir versões de um <i>dataset</i> do grupo.
RN-09	A exclusão de versões é lógica (<i>soft delete</i>), preservando os dados no sistema.

3.5 Controle de acesso

A plataforma armazena tanto dados públicos quanto dados privados, o que exige a identificação dos usuários e a restrição de operações de acordo com suas responsabilidades. A autenticação verifica o controle dos autenticadores associados à conta, conforme a abordagem das diretrizes de identidade digital do NIST (TEMOSHOK et al., 2025). A autorização determina quais recursos e operações são permitidos e pode ser organizada por papéis, conforme o modelo de Sandhu, Ferraiolo e Kuhn (2000).

No DataRural, a autenticação ocorre quando o usuário apresenta suas credenciais. Após a verificação, o servidor mantém a identidade autenticada entre diferentes requisições por meio de uma sessão (TEMOSHOK et al., 2025). Um identificador de sessão é enviado ao navegador e utilizado nas interações seguintes, permitindo que o servidor reconheça o usuário sem solicitar novamente a senha em cada página. As senhas não são armazenadas em texto simples: utiliza-se uma função de derivação acompanhada de um valor aleatório (*salt*), conforme recomendado pelo NIST (TEMOSHOK et al., 2025).

A autorização é organizada por meio do controle de acesso baseado em papéis,

conhecido como RBAC (*role-based access control*) (SANDHU; FERRAILOLO; KUHN, 2000). Nesse modelo, permissões são associadas a papéis, e cada usuário recebe um ou mais desses papéis. O acesso é decidido a partir das funções atribuídas, evitando que cada permissão precise ser configurada individualmente para cada pessoa.

No DataRural, os papéis operam em dois níveis. Os papéis globais distinguem usuários comuns de administradores da plataforma, sendo registrados na entidade *roles* e associados ao campo *role_id* do usuário. Os papéis contextuais são válidos apenas dentro de um grupo e definem o que cada membro pode fazer em relação aos datasets daquele grupo. Assim, a mesma pessoa pode administrar uma equipe e atuar apenas como leitora em outra.

A verificação de acesso é aplicada pelo servidor antes que a requisição alcance a operação principal, por meio de componentes de *middleware*. Um *middleware* de autenticação impede o acesso de visitantes a rotas protegidas, enquanto a autorização mais específica também considera o recurso solicitado, pois estar autenticado não significa possuir permissão para alterar qualquer registro. A interface pode ocultar ou desabilitar ações não permitidas para tornar o sistema mais compreensível, mas essa medida não substitui a validação no servidor, pois requisições podem ser construídas sem utilizar os botões da página.

3.6 Modelagem de dados

A modelagem de dados do DataRural foi orientada pelas responsabilidades identificadas ao longo da proposta. O dataset ocupa a posição central do modelo, enquanto as demais entidades oferecem suporte a autenticação, autoria, licenciamento, versionamento e colaboração. A estrutura permite que a plataforma trate o arquivo enviado e suas informações descritivas como partes de um mesmo registro institucional.

A adoção de um banco de dados relacional se mostra adequada porque as relações do domínio são bem definidas. Usuários publicam datasets, datasets possuem versões, licenças são associadas a datasets e grupos reúnem usuários. Além disso, o modelo facilita a aplicação de restrições de integridade e a consulta estruturada das

informações utilizadas pela plataforma.

As subseções a seguir apresentam cada entidade, suas colunas e seus papéis no sistema. A entidade *users* concentra os dados de autenticação e perfil. As entidades *roles* e *groups/group_members* organizam os dois níveis de permissão descritos na seção anterior. A entidade *datasets* reúne os metadados do conjunto publicado, enquanto *dataset_versions* e *dataset_version_files* implementam o mecanismo de versionamento discutido no Capítulo 2. A separação entre o dataset e suas versões merece atenção especial: em vez de tratar cada publicação como um arquivo substituível, o modelo preserva cada estado anterior como uma versão distinta, vinculada ao mesmo registro. Essa decisão foi motivada pela necessidade de rastreabilidade, um dos princípios centrais da gestão de dados de pesquisa, e pela possibilidade de restaurar versões excluídas logicamente, evitando perdas acidentais. Por fim, as entidades *dataset_likes* e *dataset_favorites* registram, respectivamente, as curtidas e os favoritos dos usuários, representando formas distintas de interação: a curtida funciona como uma valorização pública, enquanto o favorito cria uma coleção pessoal para acesso rápido. A entidade *audits* registra alterações para fins de rastreabilidade interna.

3.6.1 Entidade *users*

A entidade *users* concentra os dados dos usuários cadastrados. Ela participa dos fluxos de autenticação, autoria, administração e associação com grupos. A Tabela 3.4 apresenta suas colunas.

Tabela 3.4: Estrutura da entidade *users* do DataRural, que armazena os dados de autenticação e perfil dos usuários e sua associação a um papel global.

Coluna	Tipo	Descrição
id	Integer	Chave primária do usuário.
email	Varchar	E-mail utilizado para identificação e acesso.

Coluna	Tipo	Descrição
password	Varchar	Senha armazenada em formato protegido.
full_name	Varchar	Nome completo exibido na plataforma.
username	Varchar	Nome de usuário único para identificação na plataforma.
bio	Text	Biografia do usuário.
avatar	JSON	Metadados do avatar enviado (attachment).
avatar_url	Varchar	URL do avatar externo (login social).
institution	Varchar	Instituição à qual o usuário pertence.
location	Varchar	Localização do usuário.
role_id	Integer	Papel global atribuído ao usuário.
created_at	Timestamp	Data de criação do registro.
updated_at	Timestamp	Data da alteração mais recente.

3.6.2 Entidade *roles*

A entidade *roles* define os papéis globais disponíveis na aplicação, distinguindo usuários comuns de administradores. A Tabela 3.5 apresenta sua estrutura.

Tabela 3.5: Estrutura da entidade *roles* do DataRural, que define os papéis globais de acesso, distinguindo usuários comuns de administradores da plataforma.

Coluna	Tipo	Descrição
id	Integer	Chave primária do papel.
name	Varchar	Nome atribuído ao papel.
description	Text	Explicação das permissões associadas.
created_at	Timestamp	Data de criação do registro.
updated_at	Timestamp	Data da alteração mais recente.

3.6.3 Entidade *groups*

A entidade *groups* representa espaços colaborativos vinculados a equipes, laboratórios, projetos ou unidades institucionais. A Tabela 3.6 apresenta suas colunas.

Tabela 3.6: Estrutura da entidade *groups* do DataRural, que registra os grupos colaborativos, suas finalidades e os usuários responsáveis por eles.

Coluna	Tipo	Descrição
id	Integer	Chave primária do grupo.
name	Varchar	Nome do grupo colaborativo.
description	Text	Descrição da finalidade do grupo.
owner_id	Integer	Usuário responsável pelo grupo.
created_at	Timestamp	Data de criação do registro.
updated_at	Timestamp	Data da alteração mais recente.

3.6.4 Entidade *group_members*

A entidade *group_members* registra a participação de usuários em grupos e informa o papel exercido por cada membro naquele contexto. A Tabela 3.7 apresenta sua estrutura.

Tabela 3.7: Estrutura da entidade *group_members* do DataRural, que associa usuários a grupos colaborativos e registra o papel de cada membro no respectivo grupo.

Coluna	Tipo	Descrição
id	Integer	Chave primária da associação.
group_id	Integer	Grupo ao qual o usuário pertence.
user_id	Integer	Usuário associado ao grupo.

Coluna	Tipo	Descrição
role	Varchar	Papel exercido no grupo (owner, admin, editor).
created_at	Timestamp	Data de entrada no grupo.
updated_at	Timestamp	Data da alteração mais recente.

3.6.5 Entidade *licenses*

A entidade *licenses* mantém as licenças que podem ser vinculadas aos datasets, tornando explícitas as condições de uso e redistribuição. A Tabela 3.8 apresenta suas colunas.

Tabela 3.8: Estrutura da entidade *licenses* do DataRural, que registra as licenças associáveis aos datasets e suas condições de uso e redistribuição.

Coluna	Tipo	Descrição
id	Integer	Chave primária da licença.
name	Varchar	Nome resumido da licença.
description	Text	Termos ou explicação da licença.
created_at	Timestamp	Data de criação do registro.
updated_at	Timestamp	Data da alteração mais recente.

3.6.6 Entidade *dataset_areas*

A entidade *dataset_areas* armazena as áreas temáticas disponíveis para classificação dos datasets, permitindo filtragem e navegação por categoria. A Tabela 3.9 apresenta sua estrutura.

Tabela 3.9: Estrutura da entidade *dataset_areas* do DataRural, que registra as áreas temáticas utilizadas na classificação dos conjuntos de dados.

Coluna	Tipo	Descrição
id	Integer	Chave primária da área.
name	Varchar	Nome da área temática.
code	Varchar	Código identificador da área.
description	Text	Descrição da área.
icon	Varchar	Ícone representativo da área.
color	Varchar	Cor associada à área.
created_at	Timestamp	Data de criação do registro.
updated_at	Timestamp	Data da alteração mais recente.

3.6.7 Entidade *datasets*

A entidade *datasets* reúne os metadados e configurações centrais de cada conjunto de dados publicado. Por meio dela são definidos autoria, licença, visibilidade, status, área, unidade responsável e demais informações necessárias para contextualização. A Tabela 3.10 apresenta suas colunas.

Tabela 3.10: Estrutura da entidade *datasets* do DataRural, que reúne os metadados descritivos e as associações de autoria, grupo e licença, além das configurações de visibilidade de cada conjunto de dados.

Coluna	Tipo	Descrição
id	Integer	Chave primária do dataset.
user_id	Integer	Usuário responsável pela publicação.
group_id	Integer	Grupo associado ao dataset, quando houver.

Coluna	Tipo	Descrição
license_id	Integer	Licença aplicada ao dataset, quando definida.
name	Varchar	Título do conjunto de dados.
description	Text	Descrição detalhada do dataset.
path	Varchar	Referência lógica ao local de armazenamento.
is_public	Boolean	Indica se o acesso é público ou privado.
status	Varchar	Situação atual do dataset.
area	Integer	Área temática do dataset (referência a dataset_areas).
unit	Varchar	Unidade acadêmica ou administrativa responsável.
region	Varchar	Abrangência geográfica dos registros.
period	Varchar	Intervalo temporal coberto pelos dados.
tags	JSON	Palavras-chave utilizadas para indexação.
usability_score	Numeric	Indicador de completude calculado a partir da análise do arquivo enviado.
created_at	Timestamp	Data de criação do registro.
updated_at	Timestamp	Data da alteração mais recente.

3.6.8 Entidade *dataset_versions*

A entidade *dataset_versions* guarda as diferentes versões associadas a um dataset, conforme discutido na Seção 2.5. Com essa separação, uma atualização não elimina o histórico anterior e o sistema preserva a rastreabilidade do arquivo utilizado. A exclusão lógica (*soft delete*) é aplicada por meio do campo *is_deleted*: em vez de remover definitivamente o registro, o sistema marca a versão como excluída, mantendo os dados necessários para auditoria ou restauração. Essa estratégia reduz o risco de perda acidental, mas exige que registros marcados como excluídos não

apareçam como ativos e que sua restauração respeite as mesmas permissões das demais operações. A Tabela 3.11 apresenta a estrutura da entidade.

Tabela 3.11: Estrutura da entidade *dataset_versions* do DataRural, que registra as versões de cada conjunto de dados e sua marcação de exclusão lógica, preservando o histórico.

Coluna	Tipo	Descrição
id	Integer	Chave primária da versão.
dataset_id	Integer	Dataset ao qual a versão pertence.
name	Varchar	Identificador sequencial da versão.
path	JSON	Metadados do arquivo principal da versão (attachment).
is_deleted	Boolean	Indica se a versão foi marcada como excluída (<i>soft delete</i>).
created_at	Timestamp	Data de criação da versão.
updated_at	Timestamp	Data da alteração mais recente.

3.6.9 Entidade *dataset_version_files*

A entidade *dataset_version_files* armazena os arquivos individuais de cada versão do dataset, suportando múltiplos arquivos CSV por versão (conforme o requisito RF-02 da Tabela 3.1). A Tabela 3.12 apresenta sua estrutura.

Tabela 3.12: Estrutura da entidade *dataset_version_files* do DataRural, que registra os arquivos CSV de cada versão de um dataset, identificando o arquivo principal e a ordem de exibição.

Coluna	Tipo	Descrição
id	Integer	Chave primária do arquivo.

Coluna	Tipo	Descrição
dataset_version_id	Integer	Referência à versão do dataset.
name	Varchar	Nome original do arquivo enviado.
path	JSON	Metadados do arquivo armazenado (attachment).
is_primary	Boolean	Indica se é o arquivo principal da versão.
sort_order	Integer	Ordem de exibição do arquivo dentro da versão.
created_at	Timestamp	Data de criação do registro.
updated_at	Timestamp	Data da alteração mais recente.

3.6.10 Entidade *dataset_likes*

A entidade *dataset_likes* registra as curtidas dos usuários em datasets. A Tabela 3.13 apresenta sua estrutura.

Tabela 3.13: Estrutura da entidade *dataset_likes* do DataRural, que registra as curtidas por meio da associação entre cada dataset e o usuário que o curtiu.

Coluna	Tipo	Descrição
id	Integer	Chave primária da curtida.
dataset_id	Integer	Referência ao dataset curtido.
user_id	Integer	Referência ao usuário que curtiu.
created_at	Timestamp	Data de criação do registro.
updated_at	Timestamp	Data da alteração mais recente.

3.6.11 Entidade *dataset_favorites*

A entidade *dataset_favorites* registra os datasets favoritados por cada usuário, possibilitando acesso rápido a conjuntos de interesse pessoal. A Tabela 3.14 apresenta sua estrutura.

Tabela 3.14: Estrutura da entidade *dataset_favorites* do DataRural, que associa usuários aos datasets salvos como favoritos para acesso pessoal rápido.

Coluna	Tipo	Descrição
id	Integer	Chave primária do favorito.
dataset_id	Integer	Referência ao dataset favoritado.
user_id	Integer	Referência ao usuário que favoritou.
created_at	Timestamp	Data de criação do registro.
updated_at	Timestamp	Data da alteração mais recente.

3.6.12 Entidade *audits*

A entidade *audits* registra as alterações realizadas nas entidades do sistema para fins de auditoria e rastreabilidade. Cada evento armazena o tipo da operação, os valores anteriores e posteriores, o usuário responsável e informações da requisição. A Tabela 3.15 apresenta sua estrutura.

Tabela 3.15: Estrutura da entidade *audits* do DataRural, que registra alterações nas entidades do sistema, incluindo a operação realizada, os valores alterados e a identificação do responsável.

Coluna	Tipo	Descrição
id	Integer	Chave primária do registro de auditoria.
auditable_id	BigInt	ID da entidade auditada.
auditable_type	Varchar	Tipo da entidade auditada.
event	Varchar	Tipo de evento (created, updated, deleted).
old_values	JSON	Valores anteriores à alteração.
new_values	JSON	Valores posteriores à alteração.

Coluna	Tipo	Descrição
user_id	Varchar	ID do usuário responsável pela alteração.
url	Varchar	URL da requisição que gerou a alteração.
ip_address	Varchar	Endereço IP da requisição.
user_agent	Varchar	User agent da requisição.
created_at	Timestamp	Data de criação do registro.
updated_at	Timestamp	Data da alteração mais recente.

Capítulo 4

Implementação

Este capítulo apresenta o sistema desenvolvido a partir dos requisitos e da modelagem definidos no Capítulo 3. Inicialmente, são descritas a arquitetura e as decisões tecnológicas que sustentam a aplicação. Em seguida, as funcionalidades são apresentadas por meio dos fluxos de uso, das interfaces e dos mecanismos de persistência e controle de acesso envolvidos em cada operação. Ao final, uma síntese relaciona as funcionalidades descritas aos requisitos da proposta e delimita o alcance da implementação.

4.1 Arquitetura da aplicação

A arquitetura do DataRural adota uma abordagem *fullstack* monolítica modular, na qual servidor, interface e persistência residem em um mesmo projeto, mas são organizados em domínios independentes. Essa decisão foi tomada em vez de separar a aplicação em uma API REST e um cliente dedicado porque, neste estágio do projeto, não se justifica a complexidade de manter dois sistemas sincronizados, com duplicação de validações, permissões e contratos de dados. A abordagem integrada permite que uma alteração em uma regra de negócio seja refletida imediatamente na interface, sem necessidade de atualizar também um contrato de API.

O código é mantido em um monorepo gerenciado com Turborepo e pnpm works-

paces. Conforme discutido por Potvin e Levenberg (2016), a centralização do código em um repositório único simplifica a gestão de dependências e viabiliza alterações atômicas entre múltiplos pacotes sem a sobrecarga de publicar e versionar artefatos intermediários. A aplicação web reside em `apps/web`, enquanto componentes reutilizáveis e configurações compartilhadas ficam em diretórios sob `packages/`. A alternativa de manter repositórios separados exigiria um processo de versionamento e publicação de pacotes entre os projetos, introduzindo complexidade que não se justifica para uma equipe pequena. Com o monorepo, alterações em componentes compartilhados, como o pacote `packages/ui`, são imediatamente visíveis na aplicação.

A Figura 4.1 apresenta a organização do monorepo do DataRural, distinguindo os módulos da aplicação web dos pacotes compartilhados de componentes e configurações.




Figura 4.1: Estrutura de diretórios do monorepo do DataRural, com os módulos da aplicação web e os pacotes de componentes e configurações compartilhadas.

A estrutura interna da aplicação foi dividida por domínios. Em vez de manter todos os modelos, controladores e componentes em diretórios globais, os recursos

relacionados são aproximados em módulos como *auth*, *dataset*, *groups* e *users*. O módulo *auth* concentra cadastro, entrada, recuperação de acesso e demais operações relacionadas à sessão. O módulo *dataset* reúne os modelos e fluxos de publicação, consulta, edição e versionamento. O módulo *groups* trata a criação de equipes e a associação de membros, enquanto o módulo *users* mantém perfil e operações administrativas sobre contas. Essa divisão favorece a identificação do local responsável por uma regra e acompanha os conceitos apresentados no modelo de dados.

As requisições seguem o fluxo característico do padrão *Model-View-Controller* (MVC) (KRASNER; POPE, 1988). Inicialmente, a rota identifica a operação solicitada e aplica os *middlewares* necessários. Em seguida, os dados de entrada são validados e o controlador aciona os modelos ou serviços do domínio. Após a persistência, o servidor pode redirecionar o usuário ou renderizar uma página React por meio do Inertia.js. Operações com anexos incluem ainda a validação e o armazenamento do arquivo antes da confirmação da versão.

4.2 Decisões tecnológicas

A seleção das tecnologias considerou as necessidades funcionais do DataRural e a integração entre as diferentes partes da aplicação. Como o sistema reúne autenticação, formulários, persistência de metadados, envio de arquivos e páginas interativas, optou-se por uma pilha *fullstack* baseada em TypeScript. Essa escolha permite compartilhar conceitos e tipos entre servidor e interface, além de reduzir mudanças de contexto durante o desenvolvimento. As subseções a seguir apresentam cada componente da pilha adotada e justificam as decisões que motivaram sua escolha.

4.2.1 Servidor: AdonisJS e TypeScript

O AdonisJS foi escolhido como *framework* do lado servidor. O problema a ser resolvido nesta camada envolve, a cada requisição, validar entrada de dados, verificar identidade e permissões, orquestrar operações sobre múltiplas entidades relacionais e gerenciar anexos de arquivos. Um *framework* que oferece esses recursos

de forma integrada reduz o número de decisões de cola e diminui a superfície de incompatibilidades entre bibliotecas independentes.

A escolha considerou alternativas como NestJS, Express e Fastify. O NestJS oferece uma arquitetura baseada em decorators e injeção de dependências, mas adiciona uma camada de abstração que se mostrou desnecessária para o escopo deste projeto. O Express e o Fastify fornecem menor estrutura nativa: funcionalidades como validação, ORM, autenticação e autorização precisam ser adicionadas por meio de bibliotecas de terceiros, o que aumenta o custo de integração e manutenção. O AdonisJS foi preferido porque integra nativamente rotas, controladores, validações, *middlewares*, políticas de autorização, ORM (Lucid) e suporte a sessões, além de oferecer integração direta com o Inertia.js.

O uso de TypeScript contribui para explicitar os formatos esperados pelos métodos e pelas entidades. Essa característica é especialmente útil no tratamento de datasets, versões e arquivos, pois reduz ambiguidades entre os identificadores e os metadados manipulados em cada etapa.

4.2.2 Interface: React e Inertia.js

O React foi adotado para a construção da interface. A principal decisão nesta camada não foi qual biblioteca de componentes usar, mas como conectar o servidor à interface sem duplicar regras de negócio. A abordagem convencional, baseada em uma API REST consumida por um cliente separado, exige que validações, permissões e transformações de dados sejam expressas duas vezes: uma no servidor e outra no cliente. O Inertia.js resolve esse problema ao eliminar a API intermediária. O servidor resolve a rota, consulta os dados necessários e entrega as propriedades da página ao componente React correspondente. As navegações seguintes são realizadas sem recarga integral do documento, mantendo a experiência de uma aplicação de página única.

Foram consideradas alternativas como Vue.js e Angular para a camada de componentes. O Vue oferece uma curva de aprendizado menor, mas possui um ecossistema relativamente menor para as necessidades do projeto. O Angular adota uma es-

estrutura mais rígida e complexa. O React foi escolhido por combinar flexibilidade, ecossistema extenso de bibliotecas de componentes e familiaridade dos autores com sua abordagem.

4.2.3 Persistência: PostgreSQL e Lucid ORM

O PostgreSQL armazena os dados relacionais da plataforma. A adoção de um banco relacional é adequada ao domínio porque as associações possuem significado direto e precisam manter integridade referencial: uma versão deve pertencer a um dataset existente, um membro deve referenciar um usuário e um grupo, e a licença associada deve corresponder a uma opção cadastrada.

O acesso ao banco é realizado por meio do Lucid ORM, integrado ao AdonisJS. Os modelos representam as entidades apresentadas no Capítulo 3, enquanto as migrações registram a evolução do esquema. Dessa forma, a estrutura das tabelas pode ser recriada de modo controlado em diferentes ambientes.

Os arquivos CSV não são armazenados nas tabelas relacionais. O banco mantém os metadados e as referências para os anexos, separando as consultas da aplicação do armazenamento físico. Essa decisão evita transformar o banco em um repositório de objetos binários e facilita uma futura substituição do armazenamento local por um serviço de objetos.

4.2.4 Armazenamento de arquivos

O envio e a recuperação dos arquivos são tratados pelo pacote `@jrmc/adonis-attachment`. Na configuração adotada, os anexos são mantidos em `storage/uploads`, e o banco registra os metadados necessários para localizá-los. A abstração de armazenamento impede que os controladores dependam diretamente de operações específicas do sistema de arquivos, facilitando uma eventual migração para armazenamento em nuvem.

Cada versão pode possuir mais de um CSV, conforme previsto pelo requisito RF-02. A entidade `dataset_version_files` registra cada anexo individualmente, incluindo

seu nome, posição e indicação de arquivo principal. Além dos CSV enviados, o sistema gera um arquivo `README.md` para cada nova versão, consolidando informações descritivas existentes no momento da publicação.

4.2.5 Interface e componentes visuais

A interface utiliza um sistema de design próprio, desenvolvido com CSS convencional e variáveis CSS. Os componentes reutilizáveis ficam no pacote `packages/ui`, separando elementos genéricos das páginas específicas da plataforma. O Radix UI é utilizado de forma pontual, apenas nos componentes em que suas primitivas são necessárias, não constituindo a base de toda a interface. O conjunto foi estruturado para responder a diferentes larguras de tela.

4.2.6 Ambiente de desenvolvimento

No ambiente de desenvolvimento, o PostgreSQL, o pgAdmin e o Mailpit são executados em contêineres Docker. O pgAdmin auxilia na inspeção do banco de dados, e o Mailpit recebe as mensagens de e-mail geradas pela aplicação. A utilização de contêineres torna esses serviços reproduzíveis e reduz diferenças de configuração entre as máquinas dos desenvolvedores.

4.3 Funcionalidades implementadas e interfaces

A apresentação das funcionalidades acompanha o percurso de utilização do DataRural: acesso ao catálogo, autenticação, publicação, consulta e manutenção dos conjuntos de dados. Diferentemente do mockup discutido na Seção 3.3, as capturas de tela a seguir ilustram a interface desenvolvida e são acompanhadas da descrição das operações correspondentes. Os valores exibidos nas imagens contextualizam a navegação, mas não são utilizados como resultados de uma avaliação experimental ou como indicadores de adoção institucional.

4.3.1 Página inicial e consulta ao catálogo

O acesso público começa pela página inicial, apresentada na Figura 4.2. A tela reúne uma barra de busca, indicadores do acervo, categorias de conhecimento e cartões de datasets. Cada cartão apresenta informações resumidas da publicação, como título, unidade responsável, palavras-chave e licença, permitindo uma primeira seleção sem abrir individualmente todos os conjuntos.




Figura 4.2: Página inicial do DataRural, com busca de datasets públicos, indicadores do acervo e catálogo organizado por áreas de conhecimento da UFRRJ.

O visitante pode utilizar a busca e a filtragem por área temática para localizar

publicações e, em seguida, acessar a página de detalhes do conjunto escolhido. A consulta e o download de conteúdo público não exigem autenticação. Dessa forma, a separação entre navegação pública e operações de gerenciamento concretiza a distinção de acesso prevista na proposta: a identificação do usuário é exigida quando ele pretende publicar ou utilizar recursos pessoais, e não apenas para conhecer o acervo.

4.3.2 Autenticação e controle de acesso

A tela de autenticação, apresentada na Figura 4.3, oferece entrada por e-mail e senha, recuperação de acesso, encaminhamento para cadastro e a opção de acesso por conta Google. Após a autenticação, o usuário passa a acessar os recursos de publicação, grupos e favoritos. O acesso ao painel administrativo depende, adicionalmente, do papel global atribuído à conta.




Figura 4.3: Tela de autenticação do DataRural, com acesso por e-mail e senha ou conta Google para utilização das funcionalidades restritas a usuários autenticados.

No servidor, a identidade autenticada é mantida por meio dos recursos de sessão do AdonisJS. O módulo Shield fornece proteção contra *cross-site request forgery* (CSRF), complementando os mecanismos de autenticação. As rotas de publicação, gerenciamento de grupos, favoritos e administração aplicam *middleware* de autenticação antes de executar as operações correspondentes.

A autorização considera também o recurso solicitado. Nos datasets individuais, a verificação utiliza a associação entre o conjunto e seu proprietário; nos datasets vinculados a grupos, considera a participação do usuário e o papel registrado em *group_members*. O papel global, associado ao campo *role_id* de *users*, controla as

operações administrativas. Essa separação implementa os dois níveis de permissão definidos na Seção 3.5, evitando que a autenticação, isoladamente, seja suficiente para modificar qualquer publicação.

4.3.3 Publicação de datasets

A publicação é realizada por um assistente guiado de cinco etapas, em contraste com o formulário único da primeira interface do projeto, apresentado na Figura 3.4. O fluxo reúne a seleção dos arquivos, o preenchimento dos metadados, a descrição das colunas, a definição da licença e a revisão final. A divisão permite que o usuário confira separadamente o conteúdo enviado e as informações que contextualizam sua utilização.

Na primeira etapa, apresentada na Figura 4.4, o usuário seleciona os arquivos CSV. A interface identifica o arquivo principal e oferece um controle para adicionar outros arquivos à mesma publicação. A captura mostra um arquivo com 1.000 linhas e 12 colunas, acompanhado de uma prévia das três primeiras linhas e dos tipos identificados. Também são apresentados indicadores de leitura do arquivo e uma estimativa de usabilidade, permitindo uma inspeção inicial antes do preenchimento dos metadados. O escopo adotado limita o envio ao formato CSV, com até 25 MB por arquivo.

DataRural
v1.0.0 - DATASETS

Datasets Meus datasets Favoritos Grupos Gestão

Administrador

Início Meus datasets Publicar Dataset

Publicar Dataset

Preencha as etapas abaixo para disponibilizar seu conjunto de dados.

Publicar Dataset

ETAPA 1: Arquivo

ETAPA 2: Metadados

ETAPA 3: Esquema

ETAPA 4: Licença

Envie seu arquivo de dados

Faça o upload do conjunto. Detectamos colunas, tipos e qualidade automaticamente.

Arquivos selecionados (1)

customers-1000.csv (Visualizar preview)

0.56 MB • 1.000 linhas • 12 colunas

PRÉ-VISUALIZAÇÃO: CUSTOMERS-1000.CSV (PRINCIPAL)

primeiras 3 linhas de 1.000

#	Index	Customer Id	First Name	Last Name	Company	City	Co
1	#INDEX	TEXT(50)	TEXT(50)	TEXT(50)	TEXT(50)	TEXT(50)	TEXT(50)
2	1	d014d03dc7abdc	Andrew	Goodman	Stewart Flynn	Rowlandburg	Macao
3	2	2854172c8b65ec3	Alvin	Lane	Terry, Proctor and Lawrence	Bohlsde	Papua N
4	3	d79fd48f9582ac	Jenna	Harding	Balloy Group	Montgomery	China

12 colunas • 1 numérico • 10 texto • 1 data • 0 geo — Tipos inferidos automaticamente para customers-1000.csv

VALIDAÇÃO DE QUALIDADE: CUSTOMERS-1000.CSV

Codificação UTF-8
Arquivo não tem caracteres inválidos.

Cabeçalho detectado
12 colunas nomeadas na primeira linha.

Nenhuma linha vazia
Nenhuma linha possui dados estruturados.

Tipos consistentes
Nenhuma linha tem o tipo detectado.

Usabilidade média estimada: excelente
Nota calculada considerando a média de qualidade dos 1 arquivos CSV enviados.

Anterior Próximo

© 2020 Universidade Federal do Rio de Janeiro - DataRural

Figura 4.4: Etapa 1 do assistente de publicação de datasets do DataRural: envio do arquivo CSV, identificação de sua estrutura e pré-visualização das primeiras linhas.

A segunda etapa, ilustrada na Figura 4.5, reúne título, descrição, unidade ou instituto, área de conhecimento, período de cobertura, região e palavras-chave. Esses campos correspondem às informações descritivas da entidade *datasets*. Seu preenchimento permite que a publicação seja identificada por características do conteúdo, e não apenas pelo nome do arquivo armazenado.

The screenshot shows the 'Publicar Dataset' interface in the DataRural system. The main heading is 'Publicar Dataset' with a subtext 'Preencha as etapas abaixo para disponibilizar seu conjunto de dados.' and a 'Sair sem salvar' button. The current step is 'Descreva o dataset', with a note: 'Boas metadados tornam seus dados encontráveis e reutilizáveis pela comunidade.' The form contains several input fields: 'Título do dataset' (with an example: 'Ex.: Dados Meteorológicos (2010-2024)') and 'Descrição' (with an example: 'Descreva o que o conjunto contém, como foi coletado, a frequência das medições e seus usos recomendados.'). There are dropdown menus for 'Unidade / Instituto' (selected: 'Instituto de Ciências Exatas') and 'Área de conhecimento' (selected: 'Ciências Biológicas'). Other fields include 'Período de cobertura' (2010 - 2024), 'Região / Local' (Nova Iguaçu, RJ), and 'Tipo' (with a placeholder 'Digite e pressione Enter...'). Navigation buttons 'Anterior' and 'Próximo' are at the bottom of the form. The footer shows '© 2024 Universidade Federal Rural do Rio de Janeiro - DataRural'.

Figura 4.5: Etapa 2 do assistente de publicação de datasets do DataRural: preenchimento dos metadados que descrevem o conjunto de dados, seu vínculo institucional e sua abrangência temporal e espacial.

Na terceira etapa, apresentada na Figura 4.6, a interface lista as colunas do CSV e disponibiliza controles para revisão dos tipos e preenchimento das descrições. Esse dicionário de colunas complementa os metadados gerais: enquanto o título e a descrição contextualizam o conjunto, a documentação por coluna esclarece o significado de cada atributo. A revisão pelo responsável continua necessária, pois um tipo identificado automaticamente não determina, por si só, o significado científico da variável.




Figura 4.6: Etapa 3 do assistente de publicação de datasets do DataRural: revisão dos tipos e preenchimento das descrições das colunas do CSV para compor o dicionário de dados.

A quarta etapa, ilustrada na Figura 4.7, separa a escolha da licença da definição de visibilidade. A tela apresenta opções como CC BY 4.0, CC BY-SA 4.0, CC BY-NC 4.0, CC0 e ODbL, além de uma alternativa personalizada. A visibilidade determina se o conteúdo será público ou restrito; no controle de acesso descrito neste trabalho, os conjuntos privados são acessíveis ao proprietário ou aos membros autorizados do grupo associado. A seleção realizada nessa etapa é utilizada em conjunto com as verificações de autorização do servidor.




Figura 4.7: Etapa 4 do assistente de publicação de datasets do DataRural: seleção da licença de uso e definição da visibilidade pública ou privada do conjunto de dados.

Na quinta etapa, apresentada na Figura 4.8, o usuário confere um resumo do arquivo, dos metadados e das condições de uso e acesso. A interface oferece atalhos para revisar as informações e exige o aceite da declaração de conformidade antes da confirmação. Esse aceite registra a manifestação do responsável, mas não substitui a análise do conteúdo que ele pretende disponibilizar.

Figura 4.8: Etapa 5 do assistente de publicação de datasets do DataRural: conferência das informações cadastradas e aceite da declaração de conformidade institucional antes de concluir a publicação.

A conclusão do fluxo associa os metadados da publicação ao usuário responsável e cria a versão inicial do dataset. Os registros de *datasets*, *dataset_versions* e *dataset_version_files* são criados em uma transação relacional, enquanto os anexos são mantidos no armazenamento de arquivos descrito anteriormente. Essa divisão distingue o registro institucional do conjunto, o estado de seus dados em uma versão e cada arquivo que compõe esse estado. O arquivo `README.md`, gerado para a versão, reúne as informações descritivas disponíveis no momento da publicação.

4.3.4 Exploração e download dos dados

Após selecionar um dataset, o usuário acessa a página de detalhes apresentada na Figura 4.9. A interface reúne descrição, licença, informações sobre o arquivo e um dicionário de colunas. As abas separam a visão geral, o visualizador, a relação de arquivos e as versões, organizando em uma mesma página a consulta ao conteúdo e ao histórico da publicação.




Figura 4.9: Página de detalhes de um dataset no DataRural, com metadados, índice de usabilidade, dicionário de colunas e acesso às abas de visualização, arquivos e versões.

A visão geral apresenta o índice de usabilidade e informações resumidas por coluna. Esses elementos auxiliam a inspeção do material, mas não constituem uma validação da qualidade científica dos dados. Em particular, a pontuação exibida não deve ser interpretada como resultado de um teste de usabilidade da aplicação com participantes, pois sua finalidade é caracterizar aspectos da publicação.

A prévia tabular é processada no navegador: o componente interpreta o conteúdo do CSV e constrói a tabela de visualização. Assim, o usuário pode observar a estrutura e exemplos de valores antes de realizar o download. Essa funcionalidade não substitui ferramentas externas de análise e não corresponde à execução de consultas analíticas sobre o banco de dados da plataforma.

O download pode ser realizado por arquivo ou para todos os arquivos de uma versão, reunidos em um pacote ZIP. A disponibilização respeita a política de acesso do conjunto. Usuários autenticados podem também curtir a publicação ou adicioná-la aos favoritos. Essas ações são persistidas nas entidades *dataset_likes* e *dataset_favorites*, respectivamente, sem modificar a autoria ou a visibilidade do dataset. A separação permite distinguir uma interação pública de uma seleção pessoal de conjuntos para consulta posterior.

4.3.5 Gestão pessoal de datasets

O painel *Meus datasets*, apresentado na Figura 4.10, concentra o acompanhamento das publicações pelo usuário autenticado. A tela apresenta indicadores de datasets publicados e curtidas, busca textual, seleção entre conjuntos pessoais e de grupos e categorias para publicações, rascunhos e conteúdos privados. A listagem organiza título, situação, curtidas e usabilidade de cada conjunto.




Figura 4.10: Painel *Meus datasets* do DataRural, com indicadores dos conjuntos de dados do usuário autenticado e controles de busca, filtragem e início de nova publicação.

A captura apresenta o estado vazio da listagem, com orientação para ajustar os filtros ou iniciar uma publicação. Esse estado também faz parte do fluxo de uso: antes de possuir conjuntos cadastrados, o usuário já encontra o caminho para criar seu primeiro dataset. Quando há publicações disponíveis, o painel funciona como ponto de acesso à consulta e à manutenção do acervo sob sua responsabilidade, enquanto as permissões continuam sendo verificadas pelo servidor.

4.3.6 Versionamento e manutenção do histórico

A atualização dos arquivos ocorre a partir de um dataset existente. Na página de detalhes, a ação de criação de uma nova versão permite enviar o conteúdo atualizado sem substituir o registro principal do conjunto. O usuário confirma o envio, e a versão subsequente permanece vinculada ao mesmo dataset. Na Figura 4.9, o acesso à criação de versão aparece junto às ações de gerenciamento, enquanto uma aba específica organiza a consulta ao histórico.

A modelagem separa as responsabilidades dessa operação. A entidade *datasets* mantém a identificação do conjunto; *dataset_versions* registra cada versão e sua associação ao dataset; e *dataset_version_files* identifica os arquivos pertencentes a cada versão. Dessa forma, a inclusão de novos dados não exige criar outra publicação

independente, e os arquivos anteriores mantêm sua vinculação ao histórico.

A exclusão de uma versão é lógica e utiliza o campo *is_deleted*. O registro deixa de aparecer como ativo nos fluxos comuns, mas permanece armazenado para possibilitar sua restauração. A manutenção do histórico preserva a possibilidade de recuperar uma versão anterior sem confundi-la com a mais recente. Tanto a criação de versões quanto as demais operações de manutenção dependem da autorização do proprietário ou do membro habilitado no grupo.

4.3.7 Colaboração por grupos

A colaboração é implementada pelas entidades *groups* e *group_members*. A primeira registra o grupo, sua finalidade e seu proprietário; a segunda associa cada participante ao grupo e mantém o papel que ele exerce naquele contexto. A vinculação de um dataset ao grupo é registrada em *group_id*, permitindo aplicar as permissões da equipe ao conjunto de dados.

Na utilização da plataforma, o responsável pode vincular um dataset a um grupo no qual possua permissão. A consulta e a manutenção desse conjunto passam então a considerar a participação e o papel de cada membro, conforme descrito na Seção 4.3.2. Esse mecanismo permite compartilhar conjuntos privados sem torná-los públicos e sem atribuir a todos os participantes a condição de administrador da plataforma.

4.3.8 Administração e auditoria

O painel administrativo reúne a gestão de usuários e de áreas temáticas. Seu acesso é controlado pelo papel global da conta, distinguindo operações que afetam a organização da plataforma das atividades de publicação realizadas pelos usuários comuns. A manutenção das áreas temáticas, por exemplo, fornece as categorias utilizadas na classificação e na busca de datasets.

As alterações sobre entidades relevantes geram registros em *audits*. Cada registro identifica a entidade alterada, o tipo de operação, os valores anteriores e posteriores, o usuário responsável e informações da requisição. A auditoria permite, portanto,

acompanhar mudanças nos registros da aplicação, e não apenas nos arquivos enviados.

Versionamento e auditoria atendem a necessidades distintas de rastreabilidade. Uma edição da descrição pode gerar um evento de auditoria sem criar uma versão de arquivos; o envio de novos CSV, por sua vez, produz uma nova versão vinculada ao dataset. Essa distinção evita tratar toda alteração de metadados como uma atualização do conteúdo e permite acompanhar separadamente a evolução dos arquivos e as modificações nos registros que os descrevem.

4.4 Síntese da implementação e atendimento à proposta

A implementação reúne publicação, consulta, manutenção de versões, colaboração e administração em uma mesma aplicação. A Tabela 4.1 relaciona as funcionalidades descritas neste capítulo aos requisitos funcionais definidos na Tabela 3.1. Essa relação explicita como a proposta se traduz em operações e componentes do sistema, sem substituir a verificação sistemática de cada requisito por meio de testes.

Tabela 4.1: Relação entre funcionalidades descritas na implementação do DataRural, requisitos funcionais da proposta e mecanismos utilizados para realizá-las.

Funcionalidade	Requisitos	Implementação descrita
Consulta ao catálogo	RF-17, RF-18	Busca, filtragem por área e visualização prévia do CSV (Seções 4.3.1 e 4.3.4).
Autenticação	RF-13	Cadastro, entrada e manutenção da identidade por sessão, com proteção das rotas restritas (Seção 4.3.2).
Publicação e documentação	RF-01, RF-02, RF-09, RF-10	Assistente de envio de CSV, preenchimento de metadados e escolha de licença, associado aos registros do dataset e de sua versão inicial (Seção 4.3.3).

Funcionalidade	Requisitos	Implementação descrita
Controle de acesso e colaboração	RF-03, RF-04, RF-05, RF-19, RF-20	Associação de datasets a grupos e verificação de propriedade, visibilidade e papéis para as operações de consulta e manutenção (Seções 4.3.2 e 4.3.7).
Histórico de versões	RF-06, RF-07, RF-08	Criação de versões vinculadas ao dataset, exclusão lógica e restauração (Seção 4.3.6).
Download e interações	RF-11, RF-12, RF-15, RF-16	Download por arquivo ou em ZIP, com curtidas e favoritos registrados separadamente (Seção 4.3.4).
Administração e auditoria	RF-21, RF-22	Gestão de usuários e áreas temáticas, com registros das alterações nas entidades relevantes (Seção 4.3.8).

O escopo descrito utiliza CSV e armazenamento local de arquivos. A documentação das colunas, os indicadores da publicação e a prévia tabular apoiam a inspeção inicial, mas não substituem a análise científica do conteúdo nem constituem um ambiente completo de processamento de dados. A ampliação para outros formatos, a adoção de armazenamento de objetos e o consumo programático por uma API externa permanecem como possibilidades de continuidade.

As interfaces e os mecanismos apresentados demonstram a organização da solução desenvolvida, mas o trabalho não inclui uma avaliação sistemática com usuários da universidade. Também não são apresentados resultados de testes de carga ou uma avaliação abrangente de segurança. Assim, a descrição funcional não deve ser tomada como comprovação de desempenho, facilidade de uso ou prontidão para adoção institucional em larga escala. Essas limitações são retomadas no Capítulo 5.

Capítulo 5

Conclusão

Este capítulo apresenta as considerações finais sobre o desenvolvimento do DataRural. Inicialmente, são retomados o objetivo do trabalho e os principais resultados alcançados com a construção da plataforma. Em seguida, são discutidas as limitações do estágio atual e as possibilidades de continuidade do projeto.

5.1 Considerações finais

O trabalho teve como objetivo projetar e desenvolver uma plataforma institucional para apoiar a publicação, a organização, a consulta e o compartilhamento de datasets da UFRRJ. A proposta foi motivada pela necessidade de oferecer aos dados um tratamento que não se limitasse ao armazenamento de arquivos, incorporando informações descritivas, condições de acesso, autoria e histórico de atualizações.

Como resultado, foi desenvolvido o DataRural, uma aplicação web capaz de receber um ou mais arquivos CSV por versão e associá-los aos metadados definidos para o dataset. A plataforma disponibiliza consulta e download de conteúdos públicos sem exigir autenticação, ao mesmo tempo que reserva as operações de publicação e gerenciamento aos usuários identificados. A busca, os filtros por área temática e a prévia tabular complementam esse fluxo, permitindo observar o contexto e parte da estrutura do material antes de obtê-lo.

O versionamento constitui um dos resultados centrais da implementação. Em vez de substituir os arquivos de uma publicação, cada atualização pode ser registrada separadamente, mantendo a relação com o dataset original. A exclusão lógica e a possibilidade de restauração complementam esse mecanismo, enquanto os registros de auditoria documentam alterações realizadas nas entidades da aplicação. Esses recursos concretizam os requisitos de preservação do histórico apresentados no Capítulo 3.

A colaboração foi incorporada por meio de grupos e papéis contextuais. Essa organização permite que um dataset seja mantido por uma equipe sem conceder as mesmas permissões a todos os participantes. A separação entre datasets públicos e privados também possibilita utilizar a plataforma tanto para divulgação quanto para atividades internas. As verificações de acesso são executadas no servidor e utilizam a propriedade do conjunto, sua associação a um grupo e o papel exercido pelo usuário.

Do ponto de vista técnico, a aplicação foi organizada em módulos correspondentes aos principais domínios do sistema. A integração entre AdonisJS, React e Inertia.js permitiu manter o processamento das requisições e das permissões no servidor, oferecendo uma interface composta por elementos reutilizáveis. O PostgreSQL concentra os dados relacionais, enquanto os anexos permanecem separados e são associados às respectivas versões. A implementação descrita no Capítulo 4 fornece, portanto, uma base funcional para a continuidade do DataRural.

O trabalho não procura substituir repositórios científicos de alcance amplo ou plataformas comunitárias já consolidadas. Sua contribuição está na reunião de recursos de publicação, controle de acesso, colaboração e acompanhamento de versões em uma solução direcionada ao contexto institucional apresentado. Com isso, o projeto demonstra como os requisitos levantados podem ser transformados em um sistema único, mantendo pontos de extensão para necessidades que ultrapassam o escopo desta etapa.

5.2 Limitações e trabalhos futuros

O estágio atual do DataRural apresenta limitações que orientam possíveis trabalhos futuros. A primeira está relacionada aos formatos aceitos. A publicação foi implementada inicialmente para arquivos CSV, com limite de 25 MB por arquivo. Embora esse recorte atenda ao objetivo definido para o projeto, ele não contempla outros materiais que podem acompanhar uma pesquisa, como *notebooks* e outros formatos de arquivo tabulares. Uma extensão da plataforma pode criar validadores e visualizadores específicos para novos formatos, preservando o modelo de metadados e versões já adotado.

O tratamento do próprio CSV também pode ser ampliado. As interfaces apresentadas na Seção 4.3.3 incluem a revisão dos tipos e a descrição das colunas, enquanto a exploração reúne informações do conjunto e uma prévia tabular. Esses recursos e o indicador de usabilidade apoiam a inspeção inicial, mas não verificam a validade científica dos valores nem substituem a documentação produzida pelo responsável. Como continuidade, a documentação por coluna pode ser ampliada com unidades de medida e vocabulários controlados, além de identificação configurável de delimitadores e codificações, regras de validação por coluna e comparações entre versões. Essas extensões permitiriam caracterizar melhor o conteúdo e acompanhar as alterações na estrutura dos dados.

Outra possibilidade relevante para trabalhos futuros é a disponibilização de uma interface de programação de aplicações (API) voltada ao consumo programático de dados. No estágio atual, o acesso e a reutilização dos datasets dependem primordialmente da interface web e do download manual dos arquivos. A implementação de uma API RESTful ou de *endpoints* dedicados permitiria a integração direta com *scripts* e fluxos automatizados de análise de dados, além de viabilizar consultas paginadas e filtrações parciais sem a necessidade de transferir o arquivo integral. Esse recurso ampliaria a interoperabilidade do DataRural com sistemas externos e ambientes de pesquisa computacional, aplicando mecanismos de autenticação por *tokens* para assegurar o respeito às políticas de acesso e aos papéis definidos na plataforma.

A implementação priorizou os fluxos funcionais da plataforma e não incluiu, no escopo apresentado, uma avaliação sistemática com usuários da universidade. Dessa forma, não é possível concluir, a partir deste trabalho, como diferentes públicos percebem a facilidade de uso ou quais metadados consideram mais importantes durante a publicação e a busca. Estudos futuros podem conduzir testes de usabilidade com pesquisadores, estudantes e servidores, utilizando os resultados para revisar os formulários, a navegação, os papéis dos grupos e a apresentação das informações.

Também são necessárias avaliações técnicas antes de uma disponibilização institucional em maior escala. Testes de carga podem observar o comportamento da aplicação com volumes superiores de arquivos e acessos simultâneos, enquanto testes de segurança podem examinar os fluxos de autenticação, autorização e download. Testes automatizados também podem ser acrescentados para verificar as regras de negócio, especialmente nos cenários que combinam propriedade, visibilidade e papéis de grupo.

Por fim, a evolução do DataRural pode incluir integração com serviços institucionais de identidade, maior suporte a internacionalização e mecanismos de identificação persistente para publicações que necessitem de citação formal. Integrações com outros repositórios e catálogos também podem evitar que o acervo permaneça isolado. Essas extensões devem manter a separação de responsabilidades da arquitetura atual e ser acompanhadas por definições institucionais sobre curadoria, privacidade, licenciamento e conservação dos dados.

Referências

BORGMAN, C. L. The conundrum of sharing research data. *Journal of the American Society for Information Science and Technology*, v. 63, n. 6, p. 1059–1078, 2012. Disponível em: <<https://doi.org/10.1002/asi.22634>>.

Brasil. *Lei nº 13.709, de 14 de agosto de 2018: Lei Geral de Proteção de Dados Pessoais (LGPD)*. [S.l.], 2018. Disponível em: <https://www.planalto.gov.br/ccivil_03/_ato2015-2018/2018/lei/l13709.htm>. Acesso em: 05 set. 2026.

CARBON, S. et al. An analysis and metric of reusable data licensing practices for biomedical resources. *PLOS ONE*, v. 14, n. 3, p. e0213090, 2019. Disponível em: <<https://doi.org/10.1371/journal.pone.0213090>>.

CONRAD, T. O. F. et al. Making mathematical research data FAIR: Pathways to improved data sharing. *Scientific Data*, v. 11, p. 676, 2024. Disponível em: <<https://doi.org/10.1038/s41597-024-03480-0>>.

Creative Commons. *About CC Licenses*. [S.l.], s.d. Disponível em: <<https://creativecommons.org/cc-licenses/>>. Acesso em: 14 set. 2026.

Creative Commons. *CC0 1.0 Universal: Public Domain Dedication*. [S.l.], s.d. Disponível em: <<https://creativecommons.org/publicdomain/zero/1.0/>>. Acesso em: 14 set. 2026.

HIGGINS, S. The DCC curation lifecycle model. *International Journal of Digital Curation*, v. 3, n. 1, p. 134–140, 2008. Disponível em: <<https://doi.org/10.2218/ijdc.v3i1.48>>.

HOYT, C. T.; GYORI, B. M. The O3 guidelines: Open data, open code, and open infrastructure for sustainable curated scientific resources. *Scientific Data*, v. 11, p. 547, 2024. Disponível em: <<https://doi.org/10.1038/s41597-024-03406-w>>.

KLUMP, J. et al. Versioning data is about more than revisions: A conceptual framework and proposed principles. *Data Science Journal*, v. 20, p. 12, 2021. Disponível em: <<https://doi.org/10.5334/dsj-2021-012>>.

KRASNER, G. E.; POPE, S. T. A cookbook for using the model-view-controller user interface paradigm in Smalltalk-80. *Journal of Object-Oriented Programming*, v. 1, n. 3, p. 26–49, 1988.

Open Data Commons. *Open Database License (ODbL) v1.0*. [S.l.], s.d. Disponível em: <<https://opendatacommons.org/licenses/odbl/1-0/>>. Acesso em: 14 set. 2026.

PAMPEL, H. et al. Making research data repositories visible: The re3data.org registry. *PLOS ONE*, v. 8, n. 11, p. e78080, 2013. Disponível em: <<https://doi.org/10.1371/journal.pone.0078080>>.

POTVIN, R.; LEVENBERG, J. Why google stores billions of lines of code in a single repository. *Communications of the ACM*, v. 59, n. 7, p. 78–87, 2016.

QUARANTA, L.; CALEFATO, F.; LANUBILE, F. Eliciting best practices for collaboration with computational notebooks. *Proceedings of the ACM on Human-Computer Interaction*, v. 6, n. CSCW1, p. 87:1–87:41, 2022. Disponível em: <<https://doi.org/10.1145/3512934>>.

RILEY, J. *Understanding Metadata: What is Metadata, and What is it For?: A Primer*. [S.l.], 2017. Disponível em: <<https://www.niso.org/publications/understanding-metadata-2017>>. Acesso em: 18 ago. 2026.

SANDHU, R.; FERRAILOLO, D. F.; KUHN, D. R. The nist model for role-based access control: Towards a unified standard. In: *Proceedings of the Fifth ACM Workshop on Role-Based Access Control*. [s.n.], 2000. p. 47–63. Disponível em: <<https://doi.org/10.1145/344287.344301>>.

SHAFRANOVICH, Y. *Common Format and MIME Type for Comma-Separated Values (CSV) Files*. [S.l.], 2005. Disponível em: <<https://www.rfc-editor.org/rfc/rfc4180>>. Acesso em: 18 ago. 2026.

TEMOSHOK, D. et al. *Digital Identity Guidelines: Authentication and Authenticator Management*. [S.l.], 2025. Disponível em: <<https://pages.nist.gov/800-63-4/sp800-63b.html>>. Acesso em: 18 ago. 2026.

TENNISON, J.; KELLOGG, G.; HERMAN, I. *Model for Tabular Data and Metadata on the Web*. [S.l.], 2015. Disponível em: <<https://www.w3.org/TR/2015/REC-tabular-data-model-20151217/>>. Acesso em: 18 ago. 2026.

WALLIS, J. C.; ROLANDO, E.; BORGMAN, C. L. If we share data, will anyone use them? data sharing and reuse in the long tail of science and technology. *PLOS ONE*, v. 8, n. 7, p. e67332, 2013. Disponível em: <<https://doi.org/10.1371/journal.pone.0067332>>.

WILKINSON, M. D. et al. The fair guiding principles for scientific data management and stewardship. *Scientific Data*, v. 3, p. 160018, 2016. Disponível em: <<https://doi.org/10.1038/sdata.2016.18>>.