

UNIVERSIDADE FEDERAL RURAL DO RIO DE JANEIRO
INSTITUTO MULTIDISCIPLINAR

RAFAEL VIEIRA DA SILVA
HELCIO DUARTE DANTAS

**DataRural: Um Repositório
Institucional de Datasets para a
UFRRJ**

Prof. Filipe Braidão do Carmo, D.Sc.
Orientador

Nova Iguaçu, Setembro de 2026

DataRural: Um Repositório Institucional de Datasets para a UFRRJ

Rafael Vieira da Silva

Helcio Duarte Dantas

Projeto Final de Curso submetido ao Departamento de Ciência da Computação do Instituto Multidisciplinar da Universidade Federal Rural do Rio de Janeiro como parte dos requisitos necessários para obtenção do grau de Bacharel em Ciência da Computação.

Apresentado por:

Rafael Vieira da Silva

Helcio Duarte Dantas

Aprovado por:

Prof. Filipe Braida do Carmo, D.Sc.

Prof. Bruno José Dembogurski, D.Sc.

Prof. Marcel William Rocha da Silva, D.Sc.

NOVA IGUAÇU, RJ - BRASIL

Setembro de 2026

Agradecimentos

Rafael Vieira da Silva

Aos Deuses!

Helcio Duarte Dantas

Aos Deuses!

RESUMO

DataRural: Um Repositório Institucional de Datasets para a UFRRJ

Rafael Vieira da Silva e Helcio Duarte Dantas

Setembro/2026

Orientador: Filipe Braidão do Carmo, D.Sc.

A gestão de dados é essencial para a continuidade de atividades de pesquisa, extensão e administração em universidades. No entanto, os conjuntos de dados produzidos nessas instituições frequentemente permanecem dispersos em arquivos locais e sistemas sem integração, carentes de documentação, controle de acesso e preservação de histórico, o que dificulta sua localização, interpretação e reutilização. Diante dessa problemática, o presente trabalho descreve o desenvolvimento do DataRural, uma plataforma web institucional criada para centralizar e organizar a publicação e o compartilhamento de datasets na Universidade Federal Rural do Rio de Janeiro (UFRRJ). A solução permite o envio de conjuntos de dados em formato CSV acompanhados de metadados descritivos, o versionamento com preservação de estados anteriores, o controle de visibilidade entre público e privado e a colaboração por meio de grupos com papéis diferenciados. A plataforma também oferece prévia tabular dos arquivos e download individual ou em pacote. O trabalho demonstra a viabilidade de reunir, em um ambiente institucional, recursos de publicação, rastreabilidade e acesso controlado a dados acadêmicos, e sugere caminhos para aprimoramentos futuros, como suporte a novos formatos, disponibilização de API para consumo programático e avaliação de usabilidade com a comunidade universitária.

Palavras-chave: gestão de dados, repositório institucional, datasets, plataforma web, versionamento, UFRRJ.

ABSTRACT

DataRural: Um Repositório Institucional de Datasets para a UFRRJ

Rafael Vieira da Silva and Helcio Duarte Dantas

Setembro/2026

Advisor: Filipe Braida do Carmo, D.Sc.

Data management is essential for the continuity of research, outreach, and administrative activities in universities. However, datasets produced in these institutions often remain scattered across local files and unintegrated systems, lacking documentation, access control, and history preservation, which hinders their discovery, interpretation, and reuse. Addressing this problem, this work describes the development of DataRural, an institutional web platform created to centralize and organize the publication and sharing of datasets at the Universidade Federal Rural do Rio de Janeiro (UFRRJ). The solution enables uploading CSV datasets accompanied by descriptive metadata, versioning with preservation of previous states, visibility control between public and private, and collaboration through groups with distinct roles. The platform also offers tabular previews of files and individual or bundled downloads. This work demonstrates the feasibility of combining publication, traceability, and controlled access to academic data within an institutional environment, and suggests avenues for future enhancements, such as support for new formats, the provision of an API for programmatic consumption, and usability evaluation with the university community.

Keywords: data management, institutional repository, datasets, web platform, versioning, UFRRJ.

Lista de Figuras

Figura 3.1: Página inicial e catálogo público de datasets institucionais.	19
Figura 3.2: Tela de autenticação de usuários do DataRural.	20
Figura 3.3: Assistente de publicação — Etapa 1: Envio do arquivo CSV, detecção e pré-visualização tabular.	20
Figura 3.4: Assistente de publicação — Etapa 2: Preenchimento de metadados descritivos, temporais e espaciais.	21
Figura 3.5: Assistente de publicação — Etapa 3: Refinamento de esquema e dicionário de dados.	22
Figura 3.6: Assistente de publicação — Etapa 4: Seleção de licença de uso e visibilidade.	22
Figura 3.7: Assistente de publicação — Etapa 5: Revisão geral e declaração de conformidade.	23
Figura 3.8: Página de visualização detalhada e exploração de um dataset publicado.	24
Figura 3.9: Painel de gestão pessoal de conjuntos de dados do usuário auten- ticado.	25

Lista de Tabelas

3.1	Requisitos funcionais do DataRural.	26
3.2	Requisitos não funcionais do DataRural.	28
3.3	Regras de negócio do DataRural.	29
3.4	Entidade users.	32
3.5	Entidade roles.	33
3.6	Entidade groups.	33
3.7	Entidade group_members.	34
3.8	Entidade licenses.	34
3.9	Entidade dataset_areas.	35
3.10	Entidade datasets.	35
3.11	Entidade dataset_versions.	37
3.12	Entidade dataset_version_files.	37
3.13	Entidade dataset_likes.	38
3.14	Entidade dataset_favorites.	38
3.15	Entidade audits.	39

Lista de Abreviaturas e Siglas

API	<i>Application Programming Interface</i>
CSV	<i>Comma-Separated Values</i>
CSRF	<i>Cross-Site Request Forgery</i>
FAIR	<i>Findable, Accessible, Interoperable, Reusable</i>
LGPD	Lei Geral de Proteção de Dados Pessoais
MVC	<i>Model-View-Controller</i>
NIST	<i>National Institute of Standards and Technology</i>
ODbL	<i>Open Database License</i>
ORM	<i>Object-Relational Mapping</i>
RBAC	<i>Role-Based Access Control</i>
RDM	<i>Research Data Management</i>
UFRRJ	Universidade Federal Rural do Rio de Janeiro

Sumário

Agradecimentos	i
Resumo	iii
Abstract	iv
Lista de Figuras	v
Lista de Tabelas	vi
Lista de Abreviaturas e Siglas	vii
1 Introdução	1
1.1 Objetivo	3
1.2 Uso de Inteligência Artificial	3
1.3 Organização do Trabalho	4
2 Gestão e Compartilhamento de Dados de Pesquisa	5
2.1 Dados de pesquisa, datasets e metadados	5
2.2 Gestão de dados de pesquisa	6
2.2.1 Desafios da gestão de dados	7

2.2.2	Privacidade, ética e dados sensíveis	8
2.3	Princípios FAIR	9
2.4	Dados abertos e licenciamento	10
2.5	Versionamento de dados	11
2.6	Plataformas de compartilhamento de dados	12
2.7	Formato CSV e dados tabulares	13
3	DataRural	14
3.1	Trabalhos relacionados	15
3.1.1	Kaggle	15
3.1.2	Zenodo	16
3.1.3	Figshare	16
3.2	Visão geral do sistema	17
3.3	Principais fluxos e interfaces	18
3.3.1	Página inicial e catálogo público	18
3.3.2	Autenticação e acesso	18
3.3.3	Publicação de datasets	19
3.3.4	Exploração e detalhes de um dataset	23
3.3.5	Gestão pessoal de datasets	25
3.3.6	Colaboração por grupos	25
3.3.7	Painel administrativo e auditoria	26
3.4	Requisitos do sistema	26
3.4.1	Requisitos funcionais	26

3.4.2	Requisitos não funcionais	28
3.4.3	Regras de negócio	29
3.5	Controle de acesso	29
3.6	Modelagem de dados	31
3.6.1	Entidade <i>users</i>	32
3.6.2	Entidade <i>roles</i>	32
3.6.3	Entidade <i>groups</i>	33
3.6.4	Entidade <i>group_members</i>	33
3.6.5	Entidade <i>licenses</i>	34
3.6.6	Entidade <i>dataset_areas</i>	34
3.6.7	Entidade <i>datasets</i>	35
3.6.8	Entidade <i>dataset_versions</i>	36
3.6.9	Entidade <i>dataset_version_files</i>	37
3.6.10	Entidade <i>dataset_likes</i>	38
3.6.11	Entidade <i>dataset_favorites</i>	38
3.6.12	Entidade <i>audits</i>	39
4	Implementação	40
4.1	Arquitetura da aplicação	40
4.2	Decisões tecnológicas	42
4.2.1	Servidor: AdonisJS e TypeScript	42
4.2.2	Interface: React e Inertia.js	43
4.2.3	Persistência: PostgreSQL e Lucid ORM	43

4.2.4	Armazenamento de arquivos	44
4.2.5	Interface e componentes visuais	44
4.2.6	Ambiente de desenvolvimento	45
4.3	Implementação do controle de acesso	45
4.4	Implementação do versionamento	46
4.5	Implementação da exploração de dados	46
4.6	Implementação da auditoria	47
4.7	Atendimento à proposta	47
5	Conclusão	48
5.1	Considerações finais	48
5.2	Limitações e trabalhos futuros	50
	Referências	52

Capítulo 1

Introdução

A produção de dados faz parte de diferentes atividades realizadas em uma universidade. Projetos de pesquisa, ações de extensão, experimentos, levantamentos de campo e procedimentos administrativos geram registros que podem apoiar novos estudos e decisões institucionais. Entretanto, a continuidade desse valor depende da forma como os arquivos são mantidos e disponibilizados. A gestão de dados ao longo de seu ciclo de vida envolve atividades como organização, documentação, armazenamento, preservação e compartilhamento (HIGGINS, 2008). Na ausência de práticas institucionais estruturadas, o acesso e a interpretação desses registros acabam condicionados ao conhecimento tácito de seus produtores originais.

Essa dependência cria dificuldades que ultrapassam o simples armazenamento. Mesmo quando um arquivo pode ser encontrado, nem sempre estão disponíveis informações suficientes para esclarecer sua origem, o período representado, a unidade responsável ou as condições de utilização. Os metadados fornecem esse contexto ao descrever características necessárias à localização, à interpretação e à administração dos dados (RILEY, 2017). Além disso, alterações realizadas diretamente sobre um mesmo documento podem apagar estados anteriores e dificultar a identificação do material utilizado em uma pesquisa. A preservação de versões permite reconhecer mudanças e indicar com maior precisão o estado do conjunto empregado em determinado resultado (KLUMP et al., 2021). Como consequência da ausência desses cuidados, dados potencialmente úteis podem permanecer inacessíveis, ser interpretados de

maneira incorreta ou exigir um novo processo de coleta.

O compartilhamento por meios genéricos também não atende, de forma integrada, às diferentes situações encontradas no ambiente acadêmico. Alguns conjuntos devem ser divulgados publicamente, enquanto outros precisam permanecer restritos durante determinada etapa do trabalho. Os princípios FAIR — acrônimo para *Findable* (localizável), *Accessible* (acessível), *Interoperable* (interoperável) e *Reusable* (reutilizável) — orientam a descrição e a disponibilização de dados de forma a favorecer sua descoberta e reutilização (WILKINSON et al., 2016). Esses princípios não exigem que todos os dados sejam abertos: a acessibilidade pode envolver procedimentos de autenticação e autorização, desde que as condições de acesso estejam documentadas. Em atividades desenvolvidas por laboratórios, equipes ou unidades, ainda é necessário distinguir as responsabilidades de cada participante. Desse modo, uma solução institucional precisa conciliar descoberta, colaboração e controle, sem reduzir o conjunto de dados a um arquivo isolado de seu contexto.

Na Universidade Federal Rural do Rio de Janeiro (UFRRJ), a diversidade de áreas de atuação amplia a possibilidade de produção e reaproveitamento desses registros. Dados originados em diferentes setores podem interessar a pesquisadores, estudantes, gestores e ao público externo, desde que sejam apresentados de maneira organizada. Repositórios de dados contribuem para tornar os materiais de pesquisa mais visíveis e localizáveis, favorecendo sua reutilização (PAMPEL et al., 2013). Nesse contexto, este trabalho considera a necessidade de um ambiente próprio para reunir os conjuntos produzidos na instituição e apoiar a formação de um acervo que permaneça útil para além do projeto ou atividade que o originou.

Diante desse cenário, este trabalho apresenta o DataRural, uma plataforma web para a publicação e a gestão de datasets da UFRRJ. A solução busca estabelecer um ponto comum no qual os conjuntos possam ser descritos, consultados, atualizados e compartilhados conforme as permissões definidas por seus responsáveis. Ao reunir essas operações, o projeto procura reduzir a dispersão dos arquivos e favorecer a continuidade do uso dos dados produzidos na instituição.

1.1 Objetivo

O objetivo geral deste trabalho é projetar e desenvolver uma plataforma institucional de datasets para a UFRRJ, denominada DataRural, capaz de apoiar a publicação, a organização, a consulta e o compartilhamento de conjuntos de dados em formato CSV. A plataforma deve permitir que cada dataset seja acompanhado das informações necessárias à sua identificação e que seu acesso seja adequado tanto à divulgação pública quanto ao trabalho restrito de usuários e equipes.

Para alcançar esse objetivo, o sistema deve oferecer mecanismos de autenticação e autorização, possibilitar a formação de grupos com diferentes papéis e manter o histórico das atualizações realizadas nos datasets. Também deve fornecer recursos que auxiliem a descoberta e a inspeção do material publicado, como busca, classificação por área temática, apresentação de metadados, visualização prévia e download dos arquivos.

Além da disponibilização das funcionalidades, pretende-se estruturar a aplicação de maneira modular, separando as responsabilidades relacionadas à interface, às regras do sistema, à persistência das informações e ao armazenamento dos arquivos. Essa organização busca permitir a evolução gradual da plataforma e sua futura adaptação a novos formatos ou formas de integração institucional.

1.2 Uso de Inteligência Artificial

O desenvolvimento deste trabalho utilizou ferramentas baseadas em modelos de linguagem de grande escala (*Large Language Models*) em diferentes etapas do processo. A presente seção registra essa utilização de forma transparente, em atendimento às boas práticas de integridade acadêmica.

Na escrita do texto, modelos de linguagem foram empregados como auxílio à redação, revisão de coesão e sugestão de reformulações. A responsabilidade pelo conteúdo, pelas decisões conceituais e pela verificação das informações permaneceu integralmente com os autores. Na busca de referências, as ferramentas auxiliaram na

identificação de termos, autores e publicações relacionadas ao tema, servindo como ponto de partida para consultas posteriores em bases acadêmicas.

No desenvolvimento do sistema, modelos de linguagem foram utilizados como apoio à geração de código, à resolução de dúvidas técnicas e à exploração de alternativas de implementação. Os trechos sugeridos foram avaliados, adaptados e integrados ao projeto conforme as decisões de arquitetura definidas pelos autores. Na construção da interface, as ferramentas também auxiliaram na prototipação de componentes visuais e na definição de estilos.

1.3 Organização do Trabalho

Este trabalho está organizado da seguinte forma:

- **Capítulo 2 — Gestão e Compartilhamento de Dados de Pesquisa:** discute a problemática que motiva este trabalho, abordando os desafios da gestão de dados em instituições de pesquisa, os princípios FAIR, dados abertos e licenciamento, versionamento de dados, plataformas de compartilhamento e as particularidades do formato CSV;
- **Capítulo 3 — DataRural:** apresenta a proposta da plataforma, compara a solução com plataformas existentes (Kaggle, Zenodo, Figshare), demonstra os principais fluxos e interfaces do sistema, define os requisitos, o controle de acesso e a modelagem de dados;
- **Capítulo 4 — Implementação:** descreve a arquitetura adotada, justifica as decisões tecnológicas que motivaram cada escolha e detalha a implementação dos principais módulos do sistema;
- **Capítulo 5 — Conclusão:** apresenta as considerações finais, as limitações identificadas e as possibilidades de continuidade e ampliação do trabalho.

Capítulo 2

Gestão e Compartilhamento de Dados de Pesquisa

Este capítulo discute a problemática que motiva a proposta do DataRural. A questão central é a gestão dos dados produzidos em atividades de pesquisa: como organizá-los, documentá-los, preservá-los e compartilhá-los de forma que permaneçam úteis para além do projeto ou da pessoa que os gerou. Para situar essa discussão, são apresentados os conceitos de dataset e metadados, os desafios enfrentados por instituições que produzem dados sem infraestrutura dedicada, os princípios que orientam boas práticas de disponibilização, as implicações do licenciamento e da privacidade, e o papel do versionamento na preservação do histórico. O capítulo também aborda os tipos de plataformas que procuram responder a esses desafios e as particularidades do formato CSV como veículo de dados tabulares.

2.1 Dados de pesquisa, datasets e metadados

Universidades produzem dados em diferentes contextos: experimentos de laboratório, levantamentos de campo, registros administrativos, indicadores acadêmicos e projetos de extensão. Esses registros podem apoiar novos estudos, subsidiar decisões institucionais ou servir como evidência para resultados publicados. Entretanto, a simples existência de um arquivo não garante que seu conteúdo será compreendido,

localizado ou reutilizado por outras pessoas.

Um *dataset*, ou conjunto de dados, é uma coleção organizada de registros relacionados. Em uma representação tabular, cada linha geralmente corresponde a uma observação e as colunas representam atributos. Quando um dataset é publicado sem informações sobre sua origem, finalidade, unidade responsável, período coberto ou procedimentos de coleta, o custo de interpretá-lo pode superar o custo de produzir novos dados. Esse problema é agravado quando os dados passam de uma pessoa para outra ou quando o responsável original não está mais disponível para esclarecer dúvidas.

Essas informações complementares são denominadas metadados — dados que descrevem outros dados, oferecendo elementos para sua localização, interpretação, administração e reutilização (RILEY, 2017). Metadados descritivos incluem título, autoria, resumo e palavras-chave; metadados administrativos registram licença, responsável e condições de acesso; e metadados estruturais informam como os arquivos, tabelas e variáveis se relacionam (RILEY, 2017). A ausência de qualquer dessas camadas pode tornar um conjunto tecnicamente acessível, mas praticamente inutilizável.

2.2 Gestão de dados de pesquisa

A gestão de dados de pesquisa, conhecida como *Research Data Management* (RDM), reúne as práticas aplicadas ao longo do ciclo de vida dos dados produzidos em atividades de investigação (HIGGINS, 2008). Esse ciclo inclui planejamento, coleta, organização, documentação, armazenamento, controle de acesso, preservação, compartilhamento e, eventualmente, descarte. Uma gestão adequada reduz a dependência do conhecimento individual de quem produziu os arquivos e aumenta a possibilidade de utilização futura por outras pessoas.

A preocupação com a gestão de dados ganhou destaque à medida que agências de fomento, periódicos científicos e instituições passaram a exigir que os dados de pesquisa fossem tratados como produtos acadêmicos legítimos, e não apenas como

subprodutos descartáveis de uma investigação (BORGMAN, 2012). Planos de gestão de dados tornaram-se requisitos em editais de financiamento, e a transparência sobre como os dados foram coletados, armazenados e disponibilizados passou a ser considerada parte integrante da prática científica responsável.

2.2.1 Desafios da gestão de dados

Apesar do reconhecimento crescente, a gestão de dados enfrenta desafios práticos que dificultam sua adoção, especialmente em instituições que não possuem infraestrutura dedicada a esse fim.

O primeiro desafio é a **fragmentação**. Os dados permanecem distribuídos entre computadores pessoais, pastas compartilhadas, serviços de armazenamento em nuvem e sistemas internos sem integração. Quando um pesquisador se aposenta, muda de instituição ou simplesmente conclui um projeto, os arquivos produzidos podem tornar-se inacessíveis ou incompreensíveis para outras pessoas. A continuidade do valor dos dados depende de registros que não se percam junto com a memória individual de seus produtores.

O segundo desafio é a **perda de contexto**. Mesmo quando um arquivo pode ser localizado, nem sempre estão disponíveis informações suficientes para esclarecer sua origem, o período representado, a unidade responsável ou as condições de utilização. Sem metadados adequados, dois pesquisadores podem utilizar o mesmo arquivo e produzir interpretações divergentes sem perceber que estão tratando de versões diferentes ou de recortes distintos dos mesmos dados.

O terceiro desafio é a **reprodutibilidade**. Alterações realizadas diretamente sobre um mesmo documento podem apagar estados anteriores e impedir a verificação de análises passadas. Se não existe um mecanismo que preserve cada estado do conjunto, torna-se impossível determinar qual material sustentou um resultado previamente publicado (KLUMP et al., 2021).

O quarto desafio envolve as **barreiras à reutilização**. Um dataset pode estar acessível publicamente e, ainda assim, não conter informações suficientes sobre o

método de coleta, as unidades de medida, os valores ausentes ou as limitações conhecidas. Nesses casos, o esforço para compreender e validar os dados pode anular a vantagem do compartilhamento.

Esses desafios não são exclusivos de grandes centros de pesquisa. Universidades como a UFRRJ, que produzem dados em áreas variadas — da agronomia à ciência da computação, da veterinária à gestão pública —, enfrentam as mesmas dificuldades em escala própria. A ausência de um ponto centralizado de publicação faz com que dados potencialmente úteis permaneçam dispersos, não documentados ou dependentes de uma única pessoa para sua interpretação.

2.2.2 Privacidade, ética e dados sensíveis

Nem todos os dados produzidos em atividades de pesquisa podem ou devem ser disponibilizados livremente. Pesquisas que envolvem dados pessoais, informações de saúde, registros administrativos ou materiais protegidos por sigilo institucional exigem cuidados específicos que antecedem qualquer decisão de publicação.

No Brasil, a Lei Geral de Proteção de Dados Pessoais (LGPD, Lei nº 13.709/2018) estabelece regras para o tratamento de dados pessoais, incluindo a coleta, o armazenamento e o compartilhamento dessas informações (Brasil, 2018). A lei exige que o tratamento observe princípios como finalidade, adequação, necessidade e transparência. Pesquisas acadêmicas possuem previsões específicas, mas não estão isentas das obrigações de proteção.

Além das exigências legais, existem questões éticas. Dados de populações vulneráveis, comunidades tradicionais ou grupos sub-representados podem conter vieses que, se não forem documentados, podem levar à perpetuação de desigualdades em análises derivadas. A documentação das características e limitações dos dados contribui para que seus reutilizadores avaliem a adequação do material ao contexto pretendido.

Essas restrições tornam evidente que uma plataforma de gestão de dados não pode se limitar à publicação aberta. É necessário que o responsável possa definir o nível de acesso de cada conjunto e que o sistema ofereça mecanismos para que essas

condições sejam respeitadas. A abertura total não é desejável em todos os casos, e a restrição de acesso não deve ser confundida com falta de transparência.

2.3 Princípios FAIR

Diante dos desafios apresentados na seção anterior, foram propostos princípios que orientam a descrição e a disponibilização de dados de forma a favorecer sua descoberta, acesso e reutilização. Os princípios FAIR, publicados por Wilkinson et al. (2016), estabelecem que dados e outros objetos digitais devem ser:

- **Localizáveis** (*Findable*): os dados devem ser descritos com metadados ricos e receber identificadores persistentes que facilitem sua descoberta por pessoas e por sistemas computacionais;
- **Acessíveis** (*Accessible*): uma vez localizados, deve existir um procedimento claro para recuperar os dados, ainda que esse procedimento envolva autenticação ou autorização;
- **Interoperáveis** (*Interoperable*): os dados e seus metadados devem utilizar vocabulários e formatos que permitam a interpretação e o cruzamento com outros conjuntos;
- **Reutilizáveis** (*Reusable*): os dados devem ser acompanhados de informações de proveniência, licença e contexto suficientes para que terceiros possam avaliá-los e utilizá-los de forma apropriada.

É importante observar que os princípios FAIR não exigem que todos os dados sejam abertos. A acessibilidade prevista pelo segundo princípio reconhece que o acesso pode depender de procedimentos de autenticação e autorização (WILKINSON et al., 2016; GO FAIR Initiative, 2026). Um dataset pode seguir os princípios FAIR e, ainda assim, ter acesso restrito a um grupo de pesquisa ou a usuários autorizados. O que se espera é que as condições de acesso estejam documentadas e que exista um caminho definido para solicitá-lo.

A rastreabilidade complementa os princípios FAIR ao permitir identificar a origem e o histórico de um dado, incluindo as transformações ou versões pelas quais passou.

Sem essa informação, duas análises que utilizam arquivos com o mesmo nome podem produzir resultados diferentes sem que a causa seja facilmente identificada.

2.4 Dados abertos e licenciamento

A reutilização de dados depende não apenas de sua disponibilidade técnica, mas também de clareza jurídica. Um arquivo pode estar disponível publicamente para leitura e, ainda assim, não apresentar permissão clara para reutilização ou redistribuição (Open Knowledge Foundation, 2015). A ausência de uma barreira técnica não implica, por si só, autorização para qualquer forma de uso. Sem uma licença explícita, um possível reutilizador pode encontrar um dataset, baixá-lo e permanecer em dúvida sobre a possibilidade de utilizá-lo em uma pesquisa, publicação ou produto derivado.

O licenciamento resolve esse problema ao comunicar permissões e obrigações de forma padronizada. No ecossistema de dados, licenças como as da família Creative Commons (CC BY, CC BY-SA, CC0) e a Open Database License (ODbL) são amplamente utilizadas para definir condições de atribuição, compartilhamento e uso comercial (Creative Commons, 2026a; Creative Commons, 2026b; Open Data Commons, 2026). A escolha adequada depende da natureza dos dados, dos direitos existentes e dos objetivos de compartilhamento, e deve levar em conta restrições que não são resolvidas apenas por licenciamento, como privacidade, sigilo institucional e compromissos assumidos durante a coleta.

Assim, abertura e controle de acesso não são conceitos incompatíveis. Uma mesma plataforma pode reunir conjuntos abertos, conjuntos públicos com condições específicas e conjuntos privados destinados a uma equipe. O aspecto central é que o nível de acesso e as condições de reutilização sejam apresentados de maneira explícita, evitando a ambiguidade que dificulta o reaproveitamento.

2.5 Versionamento de dados

Datasets de pesquisa são frequentemente objetos em evolução. Novos registros podem ser adicionados à medida que a coleta avança, correções podem alterar valores previamente publicados e recodificações podem modificar a estrutura das variáveis. Quando essas mudanças são aplicadas diretamente sobre o mesmo arquivo, sem preservar os estados anteriores, torna-se impossível determinar qual versão dos dados sustentou um resultado previamente divulgado.

O versionamento responde a esse problema ao preservar estados sucessivos de um recurso ao longo do tempo. Em vez de substituir definitivamente um arquivo a cada alteração, o sistema cria uma nova versão e mantém a relação com as anteriores. Essa abordagem permite recuperar estados passados e informar com precisão qual versão foi utilizada em determinada análise.

No contexto dos princípios FAIR, o versionamento contribui diretamente para a localizabilidade e a reutilização. A DataCite recomenda distinguir versões relevantes de um recurso e registrar vínculos entre os respectivos identificadores persistentes (DataCite, 2026). Essa prática permite citar uma versão específica sem perder a relação com o conjunto ao qual ela pertence, favorecendo a reprodutibilidade das pesquisas.

O versionamento de datasets possui semelhanças com o versionamento de código-fonte, mas também diferenças importantes (KLUMP et al., 2021). Ferramentas como Git trabalham de forma eficiente com alterações textuais e permitem observar diferenças detalhadas entre linhas. Datasets podem conter arquivos grandes ou modificações em muitas observações, tornando menos útil a comparação linha a linha. Por isso, plataformas de dados frequentemente preservam versões completas e seus metadados, em vez de depender apenas de diferenças incrementais.

2.6 Plataformas de compartilhamento de dados

Os desafios descritos nas seções anteriores motivaram o desenvolvimento de plataformas que procuram apoiar diferentes etapas da gestão de dados. Essas plataformas assumem formatos distintos de acordo com o público atendido e a finalidade dos conjuntos publicados.

Entre as categorias mais comuns estão os repositórios de dados de pesquisa, voltados à preservação e à citação de artefatos científicos; os portais de dados abertos, utilizados por governos e instituições para disponibilizar informações de interesse público; e as plataformas colaborativas, que acrescentam recursos de exploração, interação e produção de materiais derivados (PAMPEL et al., 2013). Embora possam compartilhar funcionalidades, cada categoria enfatiza uma etapa distinta do ciclo de vida dos dados.

Um portal institucional pode combinar características dessas categorias, apoiando a divulgação pública, a preservação descritiva e o trabalho privado de grupos. Independentemente da categoria adotada, uma plataforma de compartilhamento precisa tratar o dataset como algo mais amplo do que um arquivo para download: autoria, licença, versão, descrição, condições de acesso e histórico fazem parte do objeto publicado.

A existência dessas plataformas não resolve, por si só, todos os problemas da gestão de dados. A qualidade dos metadados, a adesão dos pesquisadores e a manutenção institucional continuam sendo fatores determinantes. Ainda assim, uma solução tecnológica que centralize a publicação, a documentação e o controle de acesso pode reduzir a fragmentação e oferecer um ponto de referência para os dados produzidos em uma instituição. A análise detalhada de plataformas existentes é apresentada na seção de trabalhos relacionados do Capítulo 3.

2.7 Formato CSV e dados tabulares

O formato CSV (*Comma-Separated Values*) é amplamente utilizado como veículo de dados tabulares por sua simplicidade e compatibilidade (SHAFRANOVICH, 2005). Entretanto, essa mesma simplicidade introduz problemas relevantes para a gestão de dados.

O CSV não define obrigatoriamente os tipos das colunas, não mantém relacionamentos entre tabelas e não possui um esquema embutido capaz de descrever cada variável (TENNISON; KELLOGG; HERMAN, 2015). Datas, números decimais, valores ausentes, delimitadores e codificações de caracteres podem ser interpretados de formas diferentes por aplicações distintas. Dois arquivos identificados como CSV podem exigir configurações completamente diferentes durante a importação.

Essas limitações tornam os metadados especialmente importantes quando o CSV é o formato adotado. O nome de uma coluna nem sempre explica sua unidade de medida, os valores permitidos ou o procedimento utilizado na coleta. Um arquivo pode ser amplamente compatível do ponto de vista técnico, mas sua reutilização efetiva depende de documentação externa e de convenções consistentes. Sem essa documentação, a simplicidade do formato torna-se uma armadilha: o dado é acessível, mas não compreensível.

Uma prévia tabular — a apresentação das primeiras linhas e colunas de um arquivo antes do download completo — auxilia a inspeção rápida e permite reconhecer a estrutura do conjunto. Esse recurso, entretanto, não substitui uma análise de qualidade, uma vez que problemas podem existir em linhas não apresentadas ou depender do significado científico dos valores.

Capítulo 3

DataRural

A gestão de dados tornou-se uma dimensão cada vez mais relevante para universidades, sobretudo em instituições que produzem informações acadêmicas, administrativas e experimentais em diferentes setores. Ainda assim, é comum que esses dados permaneçam distribuídos em arquivos locais, planilhas compartilhadas informalmente, sistemas internos pouco integrados ou repositórios que não oferecem documentação suficiente para sua interpretação posterior. Quando isso ocorre, o valor dos dados diminui com o tempo, pois sua reutilização passa a depender do conhecimento individual de quem os produziu ou armazenou.

No contexto da UFRRJ, esse problema pode afetar tanto atividades de pesquisa quanto ações de gestão institucional. Dados de experimentos, levantamentos, projetos de extensão, indicadores acadêmicos ou registros administrativos podem ter utilidade para diferentes públicos, desde que estejam descritos, licenciados e organizados de maneira compreensível. Assim, a simples existência de arquivos digitais não garante transparência, reprodutibilidade ou reaproveitamento científico. É necessário oferecer um ambiente que trate o conjunto de dados como um artefato institucional, com autoria, histórico, permissões e condições claras de uso.

Com base nessa necessidade, este trabalho propõe a Plataforma Institucional de Datasets da UFRRJ, chamada neste projeto de *DataRural*. A proposta consiste em uma aplicação web voltada à publicação, consulta, atualização e organização de

datasets institucionais, tendo o formato CSV como ponto de partida. A escolha por esse formato se justifica por sua simplicidade, ampla adoção e compatibilidade com ferramentas de análise de dados, sem impedir que a plataforma evolua futuramente para outros formatos ou para integrações diretas com bases de dados.

O DataRural parte de referências conhecidas no ecossistema de dados, como Kaggle, portais de dados abertos e repositórios científicos. No entanto, seu foco não é reproduzir integralmente nenhuma dessas soluções. A intenção é adaptar conceitos consolidados, como publicação de datasets, hierarquia de usuários e licenciamento, para uma realidade universitária específica. Dessa forma, a plataforma busca apoiar tanto a divulgação pública de dados quanto o trabalho colaborativo de grupos, laboratórios e unidades acadêmicas.

3.1 Trabalhos relacionados

Antes da definição das funcionalidades do DataRural, foram observadas plataformas que já atuam no compartilhamento, preservação ou exploração de dados. Essa análise contribui para compreender quais recursos são relevantes e, ao mesmo tempo, quais limitações aparecem quando essas soluções são consideradas para um uso institucional específico. Entre as referências analisadas, destacam-se Kaggle, Zenodo e Figshare, por representarem abordagens distintas para publicação e reutilização de dados.

3.1.1 Kaggle

O Kaggle é reconhecido por reunir datasets, competições, notebooks e interações entre usuários interessados em ciência de dados. Sua relevância para este trabalho está na forma como coloca o dataset no centro da experiência: os usuários podem localizar dados, avaliá-los, reutilizá-los em análises e produzir materiais derivados dentro da própria plataforma. Esse modelo reforça a ideia de que um conjunto de dados pode ser tratado como um recurso ativo, capaz de gerar colaboração e novos estudos.

Apesar dessa contribuição conceitual, o Kaggle não foi pensado como um repositório institucional universitário. Sua lógica está associada a uma comunidade ampla e heterogênea, e não a estruturas administrativas, unidades acadêmicas, grupos internos de pesquisa ou políticas locais de acesso. Além disso, a plataforma não oferece, como foco principal, uma governança voltada à curadoria de dados produzidos dentro de uma universidade. O DataRural se diferencia justamente por trazer a centralidade dos datasets para um ambiente controlado pela instituição.

3.1.2 Zenodo

O Zenodo é amplamente utilizado para preservar e divulgar artefatos científicos, incluindo artigos, softwares e conjuntos de dados. Seu papel é relevante no contexto da ciência aberta, principalmente por possibilitar a publicação de materiais com identificação persistente e condições formais de citação. Para este projeto, o Zenodo evidencia a importância de registrar autoria, licença e informações que favoreçam a preservação de longo prazo.

Entretanto, o uso do Zenodo está mais próximo da publicação de artefatos concluídos do que da gestão cotidiana de datasets em uma instituição. A plataforma não prioriza funcionalidades como pré-visualização tabular, estatísticas descritivas por coluna, controle de acesso por grupos internos ou atualização incremental orientada a equipes de trabalho. Assim, embora seja uma referência importante para preservação científica, não contempla integralmente as necessidades operacionais previstas para o DataRural.

3.1.3 Figshare

O Figshare também se insere no campo dos repositórios científicos, oferecendo armazenamento, compartilhamento e métricas relacionadas a diferentes tipos de arquivo. Sua proposta contribui para a disseminação de resultados de pesquisa e para a valorização de dados como produtos acadêmicos. Nesse sentido, aproxima-se da preocupação deste trabalho com documentação, licenciamento e reutilização.

Ainda assim, o Figshare não resolve, por si só, demandas específicas de uma plataforma institucional customizada. Em uma universidade, pode ser necessário definir papéis internos, organizar grupos, restringir acesso a determinados datasets, associar registros a unidades acadêmicas e planejar integrações futuras com sistemas próprios. O DataRural é proposto para atuar nesse espaço, articulando práticas de repositórios científicos com necessidades locais de gestão e colaboração.

3.2 Visão geral do sistema

O DataRural é uma aplicação web que centraliza a publicação, consulta e gestão de datasets institucionais. A plataforma foi concebida para atender a dois perfis principais de usuário: o usuário comum, que publica e reutiliza dados, e o administrador, responsável pela manutenção da plataforma, gerenciamento de usuários e configuração de áreas temáticas. Alguns recursos, como a consulta e o download de datasets públicos, estão disponíveis mesmo para usuários não autenticados, ampliando o alcance da informação.

A unidade central do sistema é o dataset. Cada conjunto de dados é descrito por um conjunto de metadados — título, descrição, área temática, unidade responsável, região, período, palavras-chave e licença — que fornecem o contexto necessário para sua compreensão e reutilização. A visibilidade controla o acesso: datasets públicos são acessíveis a qualquer visitante, enquanto datasets privados ficam restritos ao proprietário ou ao grupo ao qual estão vinculados.

O sistema adota o versionamento como princípio estrutural. Cada atualização de um conjunto de dados gera uma nova versão, preservando o histórico completo de modificações e permitindo rastrear qual versão foi utilizada em determinada análise ou relatório. Versões podem ser excluídas de forma lógica e restauradas quando necessário.

Os grupos colaborativos constituem outro elemento central da plataforma. Eles representam laboratórios, equipes ou unidades institucionais e permitem que múltiplos usuários trabalhem de forma coordenada sobre os mesmos datasets, com papéis bem

definidos — dono, administrador, editor e leitor. Essa estrutura de colaboração diferencia o DataRural de repositórios de uso individual, tornando-o adequado tanto para a divulgação pública de dados quanto para o trabalho interno de equipes acadêmicas.

3.3 Principais fluxos e interfaces

As subseções a seguir apresentam os fluxos que a plataforma oferece aos seus usuários e ilustram as interfaces correspondentes. O objetivo é demonstrar como os conceitos discutidos nas seções anteriores se traduzem em funcionalidades concretas, desde a página inicial até a publicação, exploração e gestão dos dados.

3.3.1 Página inicial e catálogo público

A porta de entrada do sistema é a página inicial pública, apresentada na Figura 3.1.

A página inicial oferece uma barra de busca unificada com sugestões de termos frequentes de pesquisa, acompanhada de indicadores quantitativos sobre o acervo (total de datasets públicos, áreas de conhecimento, grupos de pesquisa e pesquisadores cadastrados). A seção central disponibiliza um catálogo navegável segmentado pelos institutos e unidades da UFRRJ e uma vitrine de datasets em destaque. Na parte inferior, há um convite direto à submissão de novos dados pela comunidade acadêmica.

A partir da página inicial, qualquer visitante pode buscar datasets, aplicar filtros por área temática, visualizar metadados e consultar informações de licença, sem necessidade de autenticação.

3.3.2 Autenticação e acesso

Para publicar datasets ou acessar funcionalidades restritas, o usuário deve autenticar-se na plataforma por meio da interface apresentada na Figura 3.2.

A interface de autenticação oferece campos para e-mail e senha, recursos de recuperação de acesso e integração com provedores de autenticação externa (*OAuth*),




Figura 3.1: Página inicial e catálogo público de datasets institucionais.

Fonte: Elaborado pelos autores (2026).

como o Google. Após a autenticação, o usuário passa a ter acesso aos módulos de publicação, gerenciamento de grupos, favoritos e, quando autorizado, ao painel administrativo.

3.3.3 Publicação de datasets

O processo de publicação foi estruturado na forma de um assistente guiado (*wizard*) composto por cinco etapas sequenciais, de modo a assegurar a completude




Figura 3.2: Tela de autenticação de usuários do DataRural.
Fonte: Elaborado pelos autores (2026).

dos metadados e a conformidade com as diretrizes institucionais.

Na primeira etapa, apresentada na Figura 3.3, o usuário realiza o envio do arquivo CSV por meio de uma área interativa de carregamento. A aplicação executa uma inspeção imediata, identificando as dimensões do arquivo, os tipos dos atributos e uma prévia das primeiras linhas. Uma validação preliminar de qualidade verifica ausência de linhas vazias, caracteres inválidos e presença de cabeçalhos nomeados, gerando uma nota inicial de usabilidade.




Figura 3.3: Assistente de publicação — Etapa 1: Envio do arquivo CSV, detecção e pré-visualização tabular.
Fonte: Elaborado pelos autores (2026).

Na segunda etapa (Figura 3.4), são informados os metadados contextuais e institucionais: título descritivo, unidade ou instituto de vínculo, descrição detalhada, área de conhecimento, cobertura temporal e espacial, e palavras-chave.

A imagem mostra a interface de usuário do sistema DataRural, especificamente a etapa 2 de publicação de um dataset. O cabeçalho da página contém o logo 'DataRural' e o subtítulo 'OFICINA DE DATASETS'. Abaixo, há uma barra de navegação com links para 'Datasets', 'Meus datasets', 'Favoritos', 'Grupos' e 'Gestão'. O usuário logado é 'Administrador'. O título principal da seção é 'Publicar Dataset', com um subtítulo explicando que o usuário deve preencher as etapas abaixo para disponibilizar seu conjunto de dados. Um botão 'Sair sem salvar' está no canto superior direito. O formulário principal, intitulado 'Descreva o dataset', contém campos para: 'Título do dataset' (com um exemplo de dados meteorológicos), 'Descrição' (com uma dica para descrever o conjunto de dados), 'Unidade / Instituto' (com uma lista suspensa selecionando 'Instituto de Ciências Exatas'), 'Área de conhecimento' (com uma lista suspensa selecionando 'Ciências Biológicas'), 'Período de cobertura' (com o valor '2010 - 2024'), 'Região / Local' (com o valor 'Nova Iguaçu, RJ') e 'Tags' (com um campo de texto para digitar e pressionar Enter). Botões 'Anterior' e 'Próximo' estão na base do formulário. O rodapé da página indica '© 2026 Universidade Federal do Rio de Janeiro - DataRural'.

Figura 3.4: Assistente de publicação — Etapa 2: Preenchimento de metadados descritivos, temporais e espaciais.

Fonte: Elaborado pelos autores (2026).

A terceira etapa (Figura 3.5) é dedicada ao dicionário de dados: a aplicação lista cada coluna detectada no CSV, permitindo validar ou alterar o tipo inferido e fornecer uma descrição em linguagem natural para cada variável. Essa funcionalidade alinha a plataforma às diretrizes FAIR de reusabilidade ao evitar atributos sem significado documentado.

Na quarta etapa (Figura 3.6), são definidas a licença de uso e a visibilidade do conjunto. O sistema oferece cartões visuais para seleção entre licenças padronizadas (CC BY 4.0, CC BY-SA 4.0, CC BY-NC 4.0, CC0, ODbL e Licença Personalizada). O usuário escolhe entre o modo público e o modo privado.

Por fim, a quinta etapa (Figura 3.7) consolida todas as informações cadastradas para conferência. Antes do envio definitivo, o usuário deve assinalar o termo de conformidade institucional, confirmando autorização para divulgação e atestando que os dados atendem à Política de Dados Abertos da UFRRJ e à Lei Geral de Proteção de Dados (LGPD).

Caso haja correções ou novas coletas, o responsável pode incluir uma nova versão,




Figura 3.5: Assistente de publicação — Etapa 3: Refinamento de esquema e dicionário de dados.

Fonte: Elaborado pelos autores (2026).




Figura 3.6: Assistente de publicação — Etapa 4: Seleção de licença de uso e visibilidade.

Fonte: Elaborado pelos autores (2026).

preservando o histórico da publicação. Versões podem ser excluídas logicamente e restauradas quando necessário.

The screenshot shows the 'Publicar Dataset' (Publish Dataset) interface in the DataRural system. The top navigation bar includes 'Datasets', 'Meus datasets', 'Favoritos', 'Grupos', and 'Gestão'. The user is logged in as 'Administrador'. The main heading is 'Publicar Dataset' with a subtext 'Preencha as etapas abaixo para disponibilizar seu conjunto de dados.' and a 'Sair sem salvar' button.

On the left, a vertical progress bar shows five steps: 'ETAPA 1 Arquivo', 'ETAPA 2 Metadados', 'ETAPA 3 Espuma', 'ETAPA 4 Licença', and 'ETAPA 5 Revisão' (highlighted in blue). The main content area is titled 'Revise e publique' (Review and publish) with the instruction 'Confira tudo antes de enviar para a curadoria DataRural.'.

The form contains three sections, each with an 'Editar' (Edit) link:

- Arquivo**:
 - Nome do arquivo: customers-1000.csv
 - Tamanho: 0.14 MB
 - Conteúdo: 1.000 linhas · 12 colunas
- Metadados**:
 - Título: Estudantes do RU no IMQ(2025)
 - Unidade: Instituto de Ciências Sociais Aplicadas
 - Área: Ciências Sociais
 - Período: 2025
 - Tags: Restaurante, Clientes
- Licença & visibilidade**:
 - Licença: CC BY 4.0
 - Visibilidade: Público

Below these sections is a checkbox: 'Confirmando que tenho autorização para publicar estes dados e que eles estão de acordo com a Política de Dados Abertos da UFRRJ e a LGPD (sem dados pessoais identificáveis).'. At the bottom are two buttons: 'Anterior' (Previous) and 'Publicar dataset' (Publish dataset).

At the bottom of the page, there is a footer: '© 2024 Universidade Federal Rural do Rio de Janeiro - DataRural'.

Figura 3.7: Assistente de publicação — Etapa 5: Revisão geral e declaração de conformidade.

Fonte: Elaborado pelos autores (2026).

3.3.4 Exploração e detalhes de um dataset

A área de exploração apresenta os datasets públicos e oferece busca e filtragem por área temática. Ao selecionar um conjunto, o usuário é direcionado para a página de detalhes, demonstrada na Figura 3.8.

Na página de detalhes, os metadados são organizados para responder a questões básicas sobre o conjunto: quem o publicou, qual unidade é responsável, qual período e região são cobertos e sob qual licença os dados podem ser utilizados. O painel central destaca o índice de usabilidade da publicação, que sintetiza dimensões de completude, credibilidade e compatibilidade. Abaixo dos indicadores, a aba de visualização apresenta o dicionário de colunas com estatísticas descritivas calculadas para cada atributo do CSV. A página também apresenta uma prévia tabular interativa, que permite reconhecer colunas e observar exemplos de valores antes do download completo.

O download pode ser realizado de forma individual por arquivo ou em lote, com




Figura 3.8: Página de visualização detalhada e exploração de um dataset publicado.
Fonte: Elaborado pelos autores (2026).

todos os arquivos de uma versão empacotados em formato ZIP. Usuários autenticados podem ainda curtir datasets e salvá-los como favoritos para acesso rápido.

3.3.5 Gestão pessoal de datasets

Para os usuários autenticados, a aplicação disponibiliza o painel de controle pessoal “Meus datasets”, ilustrado na Figura 3.9.




Figura 3.9: Painel de gestão pessoal de conjuntos de dados do usuário autenticado.
Fonte: Elaborado pelos autores (2026).

O painel reúne métricas consolidadas sobre a produção do pesquisador, exibindo a contagem total de datasets publicados, rascunhos em elaboração, curtidas acumuladas e registros mantidos em caráter privado. A tela fornece controles dedicados para busca textual, filtros combinados por status de publicação e faixa de usabilidade, e atalho direto para iniciar uma nova submissão.

3.3.6 Colaboração por grupos

Os grupos permitem que múltiplos usuários compartilhem o acesso a datasets privados. Um grupo possui um proprietário e uma lista de membros, cada um com um papel que determina as operações permitidas. Ao publicar ou editar um dataset, o usuário pode vinculá-lo a um grupo no qual possua permissão, fazendo com que a autorização passe a considerar toda a equipe. Essa decisão evita que a continuidade de um conjunto institucional fique condicionada a uma única conta.

3.3.7 Painel administrativo e auditoria

O painel administrativo reúne operações que afetam a organização global do DataRural. Administradores podem consultar e gerenciar usuários e áreas temáticas. As alterações sobre entidades relevantes produzem registros de auditoria, que documentam o tipo da operação, os valores anteriores e posteriores, o usuário responsável e informações da requisição, auxiliando a investigação de mudanças indevidas.

3.4 Requisitos do sistema

Os requisitos apresentados nesta seção organizam as capacidades esperadas para a plataforma. Eles foram definidos a partir dos objetivos do projeto e procuram traduzir, em funcionalidades e restrições, a proposta de uma solução institucional para publicação e gestão de datasets. Para facilitar a leitura, os requisitos foram separados em funcionais, não funcionais e regras de negócio.

3.4.1 Requisitos funcionais

A Tabela 3.1 apresenta os requisitos funcionais definidos para o DataRural. Esses requisitos descrevem as operações que a plataforma deve disponibilizar aos seus usuários, incluindo publicação, consulta, versionamento, colaboração e administração.

Tabela 3.1: Requisitos funcionais do DataRural.

Código	Descrição
RF-01	Permitir o upload de <i>datasets</i> em formato CSV.
RF-02	Permitir o upload de múltiplos arquivos CSV por versão do dataset.
RF-03	Permitir a criação de grupos de usuários com papéis (dono, admin, editor, visualizador).
RF-04	Permitir a criação de <i>datasets</i> privados.
RF-05	Permitir alternar a visibilidade (público/privado) de um dataset.

Código	Descrição
RF-06	Permitir o versionamento de <i>datasets</i> .
RF-07	Permitir a restauração de versões anteriores de um dataset.
RF-08	Permitir a exclusão lógica (<i>soft delete</i>) de versões.
RF-09	Permitir a descrição e o licenciamento de <i>datasets</i> publicados.
RF-10	Permitir a classificação de datasets por metadados (área, unidade, período, região, tags).
RF-11	Permitir o download individual de arquivos de um dataset.
RF-12	Permitir o download de todos os arquivos de uma versão em formato ZIP.
RF-13	Permitir o registro e autenticação de usuários.
RF-14	Permitir a edição de perfil do usuário (nome, bio, avatar, instituição, localização).
RF-15	Permitir que usuários curtam datasets.
RF-16	Permitir que usuários favoritem datasets para acesso rápido.
RF-17	Permitir a exploração e busca de datasets com filtro por área temática.
RF-18	Exibir uma prévia das primeiras linhas dos arquivos CSV de um dataset.
RF-19	Permitir a atribuição de datasets a grupos.
RF-20	Permitir a exclusão de datasets apenas pelo proprietário ou membro autorizado do grupo.
RF-21	Oferecer um painel administrativo para gestão de usuários e áreas temáticas.
RF-22	Registrar trilha de auditoria para alterações nas entidades principais.
RF-23	Oferecer suporte a internacionalização (i18n).
RF-24	Exibir perfis públicos de usuários.

3.4.2 Requisitos não funcionais

Os requisitos não funcionais, apresentados na Tabela 3.2, estabelecem restrições e qualidades esperadas para a plataforma. Eles orientam decisões de implementação relacionadas a segurança, organização do código, preservação do histórico e compatibilidade.

Tabela 3.2: Requisitos não funcionais do DataRural.

Código	Descrição
RNF-01	A solução deve ser disponibilizada como aplicação web responsiva e compatível com navegadores atuais.
RNF-02	As senhas devem ser armazenadas por meio de representação criptográfica segura.
RNF-03	O acesso a rotas protegidas deve ser controlado por <i>middleware</i> de autenticação.
RNF-04	Os arquivos enviados devem ser validados, considerando inicialmente apenas o formato CSV.
RNF-05	O código deve manter separação entre interface, regras de negócio, persistência e armazenamento de arquivos.
RNF-06	A estrutura da plataforma deve permitir evolução para novos formatos e novas fontes de dados.
RNF-07	O histórico de versões deve ser preservado para manter rastreabilidade das alterações.
RNF-08	A interface deve apresentar metadados, permissões e licenças de forma clara ao usuário.
RNF-09	As principais entidades devem ser auditáveis.
RNF-10	A organização modular do sistema deve favorecer manutenção e expansão gradual.

3.4.3 Regras de negócio

As regras de negócio, listadas na Tabela 3.3, definem condições que devem ser respeitadas pela plataforma independentemente da tecnologia adotada. Elas delimitam permissões, restrições de formato e políticas de visibilidade que orientam o comportamento esperado do sistema.

Tabela 3.3: Regras de negócio do DataRural.

Código	Descrição
RN-01	A publicação de <i>datasets</i> é restrita a usuários autenticados.
RN-02	Usuários não registrados podem visualizar e fazer download de <i>datasets</i> públicos.
RN-03	Todo <i>dataset</i> publicado deve possuir uma licença associada.
RN-04	<i>Datasets</i> não publicados são visíveis apenas pelo usuário proprietário ou membros do grupo associado.
RN-05	Nomes de <i>datasets</i> devem ser únicos no sistema.
RN-06	Cada arquivo CSV enviado deve ter no máximo 25 MB.
RN-07	Membros de grupo com papel de dono, admin ou editor podem editar <i>datasets</i> do grupo.
RN-08	Apenas membros com papel de dono ou admin podem excluir versões de um <i>dataset</i> do grupo.
RN-09	A exclusão de versões é lógica (<i>soft delete</i>), preservando os dados no sistema.

3.5 Controle de acesso

A plataforma armazena tanto dados públicos quanto dados privados, o que exige a identificação dos usuários e a restrição de operações de acordo com suas responsabilidades. Para isso, é necessário diferenciar dois processos complementares: autenticação e autorização (OWASP Foundation, 2026a). A autenticação responde à pergunta “quem é o usuário?”, enquanto a autorização determina “o que esse usuário

pode fazer?”.

No DataRural, a autenticação ocorre quando o usuário apresenta suas credenciais. Após a verificação, o servidor mantém a identidade autenticada entre diferentes requisições por meio de uma sessão (OWASP Foundation, 2026b). Um identificador de sessão é enviado ao navegador e utilizado nas interações seguintes, permitindo que o servidor reconheça o usuário sem solicitar novamente a senha em cada página. As senhas não são armazenadas em texto simples: utiliza-se uma função de derivação acompanhada de um valor aleatório (*salt*), conforme recomendado pelo NIST (TEMOSHOK et al., 2025).

A autorização é organizada por meio do controle de acesso baseado em papéis, conhecido como RBAC (*Role-Based Access Control*) (SANDHU; FERRAILOLO; KUHN, 2000). Nesse modelo, permissões são associadas a papéis, e cada usuário recebe um ou mais desses papéis. O acesso é decidido a partir das funções atribuídas, evitando que cada permissão precise ser configurada individualmente para cada pessoa.

No DataRural, os papéis operam em dois níveis. Os **papéis globais** distinguem usuários comuns de administradores da plataforma, sendo registrados na entidade *roles* e associados ao campo *role_id* do usuário. Os **papéis contextuais** são válidos apenas dentro de um grupo e definem o que cada membro pode fazer em relação aos datasets daquele grupo. Assim, a mesma pessoa pode administrar uma equipe e atuar apenas como leitora em outra.

A verificação de acesso é aplicada pelo servidor antes que a requisição alcance a operação principal, por meio de componentes de *middleware* (BERNSTEIN, 1996). Um *middleware* de autenticação impede o acesso de visitantes a rotas protegidas, enquanto a autorização mais específica também considera o recurso solicitado — estar autenticado não significa possuir permissão para alterar qualquer registro. A interface pode ocultar ou desabilitar ações não permitidas para tornar o sistema mais compreensível, mas essa medida não substitui a validação no servidor, pois requisições podem ser construídas sem utilizar os botões da página.

3.6 Modelagem de dados

A modelagem de dados do DataRural foi orientada pelas responsabilidades identificadas ao longo da proposta. O dataset ocupa a posição central do modelo, enquanto as demais entidades oferecem suporte a autenticação, autoria, licenciamento, versionamento e colaboração. A estrutura permite que a plataforma trate o arquivo enviado e suas informações descritivas como partes de um mesmo registro institucional.

A adoção de um banco de dados relacional se mostra adequada porque as relações do domínio são bem definidas. Usuários publicam datasets, datasets possuem versões, licenças são associadas a datasets e grupos reúnem usuários. Além disso, o modelo facilita a aplicação de restrições de integridade e a consulta estruturada das informações utilizadas pela plataforma.

As subseções a seguir apresentam cada entidade, suas colunas e seus papéis no sistema. A entidade *users* concentra os dados de autenticação e perfil. As entidades *roles* e *groups/group_members* organizam os dois níveis de permissão descritos na seção anterior. A entidade *datasets* reúne os metadados do conjunto publicado, enquanto *dataset_versions* e *dataset_version_files* implementam o mecanismo de versionamento discutido no Capítulo 2. A separação entre o dataset e suas versões merece atenção especial: em vez de tratar cada publicação como um arquivo substituível, o modelo preserva cada estado anterior como uma versão distinta, vinculada ao mesmo registro. Essa decisão foi motivada pela necessidade de rastreabilidade — um dos princípios centrais da gestão de dados de pesquisa — e pela possibilidade de restaurar versões excluídas logicamente, evitando perdas acidentais. Por fim, as entidades *dataset_likes* e *dataset_favorites* registram, respectivamente, as curtidas e os favoritos dos usuários, representando formas distintas de interação: a curtida funciona como uma valorização pública, enquanto o favorito cria uma coleção pessoal para acesso rápido. A entidade *audits* registra alterações para fins de rastreabilidade interna.

3.6.1 Entidade *users*

A entidade *users* concentra os dados dos usuários cadastrados. Ela participa dos fluxos de autenticação, autoria, administração e associação com grupos. A Tabela 3.4 apresenta suas colunas.

Tabela 3.4: Entidade *users*.

Coluna	Tipo	Descrição
id	Integer	Chave primária do usuário.
email	Varchar	E-mail utilizado para identificação e acesso.
password	Varchar	Senha armazenada em formato protegido.
full_name	Varchar	Nome completo exibido na plataforma.
username	Varchar	Nome de usuário único para identificação na plataforma.
bio	Text	Biografia do usuário.
avatar	JSON	Metadados do avatar enviado (attachment).
avatar_url	Varchar	URL do avatar externo (login social).
institution	Varchar	Instituição à qual o usuário pertence.
location	Varchar	Localização do usuário.
role_id	Integer	Papel global atribuído ao usuário.
created_at	Timestamp	Data de criação do registro.
updated_at	Timestamp	Data da alteração mais recente.

3.6.2 Entidade *roles*

A entidade *roles* define os papéis globais disponíveis na aplicação, distinguindo usuários comuns de administradores. A Tabela 3.5 apresenta sua estrutura.

Tabela 3.5: Entidade roles.

Coluna	Tipo	Descrição
id	Integer	Chave primária do papel.
name	Varchar	Nome atribuído ao papel.
description	Text	Explicação das permissões associadas.
created_at	Timestamp	Data de criação do registro.
updated_at	Timestamp	Data da alteração mais recente.

3.6.3 Entidade *groups*

A entidade *groups* representa espaços colaborativos vinculados a equipes, laboratórios, projetos ou unidades institucionais. A Tabela 3.6 apresenta suas colunas.

Tabela 3.6: Entidade groups.

Coluna	Tipo	Descrição
id	Integer	Chave primária do grupo.
name	Varchar	Nome do grupo colaborativo.
description	Text	Descrição da finalidade do grupo.
owner_id	Integer	Usuário responsável pelo grupo.
created_at	Timestamp	Data de criação do registro.
updated_at	Timestamp	Data da alteração mais recente.

3.6.4 Entidade *group_members*

A entidade *group_members* registra a participação de usuários em grupos e informa o papel exercido por cada membro naquele contexto. A Tabela 3.7 apresenta sua estrutura.

Tabela 3.7: Entidade `group_members`.

Coluna	Tipo	Descrição
<code>id</code>	Integer	Chave primária da associação.
<code>group_id</code>	Integer	Grupo ao qual o usuário pertence.
<code>user_id</code>	Integer	Usuário associado ao grupo.
<code>role</code>	Varchar	Papel exercido no grupo (owner, admin, editor).
<code>created_at</code>	Timestamp	Data de entrada no grupo.
<code>updated_at</code>	Timestamp	Data da alteração mais recente.

3.6.5 Entidade *licenses*

A entidade *licenses* mantém as licenças que podem ser vinculadas aos datasets, tornando explícitas as condições de uso e redistribuição. A Tabela 3.8 apresenta suas colunas.

Tabela 3.8: Entidade `licenses`.

Coluna	Tipo	Descrição
<code>id</code>	Integer	Chave primária da licença.
<code>name</code>	Varchar	Nome resumido da licença.
<code>description</code>	Text	Termos ou explicação da licença.
<code>created_at</code>	Timestamp	Data de criação do registro.
<code>updated_at</code>	Timestamp	Data da alteração mais recente.

3.6.6 Entidade *dataset_areas*

A entidade *dataset_areas* armazena as áreas temáticas disponíveis para classificação dos datasets, permitindo filtragem e navegação por categoria. A Tabela 3.9 apresenta sua estrutura.

Tabela 3.9: Entidade *dataset_areas*.

Coluna	Tipo	Descrição
id	Integer	Chave primária da área.
name	Varchar	Nome da área temática.
code	Varchar	Código identificador da área.
description	Text	Descrição da área.
icon	Varchar	Ícone representativo da área.
color	Varchar	Cor associada à área.
created_at	Timestamp	Data de criação do registro.
updated_at	Timestamp	Data da alteração mais recente.

3.6.7 Entidade *datasets*

A entidade *datasets* reúne os metadados e configurações centrais de cada conjunto de dados publicado. Por meio dela são definidos autoria, licença, visibilidade, status, área, unidade responsável e demais informações necessárias para contextualização. A Tabela 3.10 apresenta suas colunas.

Tabela 3.10: Entidade *datasets*.

Coluna	Tipo	Descrição
id	Integer	Chave primária do dataset.
user_id	Integer	Usuário responsável pela publicação.
group_id	Integer	Grupo associado ao dataset, quando houver.
license_id	Integer	Licença aplicada ao dataset, quando definida.
name	Varchar	Título do conjunto de dados.
description	Text	Descrição detalhada do dataset.

Coluna	Tipo	Descrição
path	Varchar	Referência lógica ao local de armazenamento.
is_public	Boolean	Indica se o acesso é público ou privado.
status	Varchar	Situação atual do dataset.
area	Integer	Área temática do dataset (referência a dataset_areas).
unit	Varchar	Unidade acadêmica ou administrativa responsável.
region	Varchar	Abrangência geográfica dos registros.
period	Varchar	Intervalo temporal coberto pelos dados.
tags	JSON	Palavras-chave utilizadas para indexação.
usability_score	Numeric	Indicador de completude calculado a partir da análise do arquivo enviado.
created_at	Timestamp	Data de criação do registro.
updated_at	Timestamp	Data da alteração mais recente.

3.6.8 Entidade *dataset_versions*

A entidade *dataset_versions* guarda as diferentes versões associadas a um dataset, conforme discutido na Seção 2.5. Com essa separação, uma atualização não elimina o histórico anterior e o sistema preserva a rastreabilidade do arquivo utilizado. A exclusão lógica (*soft delete*) é aplicada por meio do campo *is_deleted*: em vez de remover definitivamente o registro, o sistema marca a versão como excluída, mantendo os dados necessários para auditoria ou restauração. Essa estratégia reduz o risco de perda acidental, mas exige que registros marcados como excluídos não apareçam como ativos e que sua restauração respeite as mesmas permissões das demais operações. A Tabela 3.11 apresenta a estrutura da entidade.

Tabela 3.11: Entidade `dataset_versions`.

Coluna	Tipo	Descrição
<code>id</code>	Integer	Chave primária da versão.
<code>dataset_id</code>	Integer	Dataset ao qual a versão pertence.
<code>name</code>	Varchar	Identificador sequencial da versão.
<code>path</code>	JSON	Metadados do arquivo principal da versão (attachment).
<code>is_deleted</code>	Boolean	Indica se a versão foi marcada como excluída (<i>soft delete</i>).
<code>created_at</code>	Timestamp	Data de criação da versão.
<code>updated_at</code>	Timestamp	Data da alteração mais recente.

3.6.9 Entidade `dataset_version_files`

A entidade `dataset_version_files` armazena os arquivos individuais de cada versão do dataset, suportando múltiplos arquivos CSV por versão (conforme o requisito RF-02 da Tabela 3.1). A Tabela 3.12 apresenta sua estrutura.

Tabela 3.12: Entidade `dataset_version_files`.

Coluna	Tipo	Descrição
<code>id</code>	Integer	Chave primária do arquivo.
<code>dataset_version_id</code>	Integer	Referência à versão do dataset.
<code>name</code>	Varchar	Nome original do arquivo enviado.
<code>path</code>	JSON	Metadados do arquivo armazenado (attachment).
<code>is_primary</code>	Boolean	Indica se é o arquivo principal da versão.
<code>sort_order</code>	Integer	Ordem de exibição do arquivo dentro da versão.
<code>created_at</code>	Timestamp	Data de criação do registro.

Coluna	Tipo	Descrição
updated_at	Timestamp	Data da alteração mais recente.

3.6.10 Entidade *dataset_likes*

A entidade *dataset_likes* registra as curtidas dos usuários em datasets. A Tabela 3.13 apresenta sua estrutura.

Tabela 3.13: Entidade *dataset_likes*.

Coluna	Tipo	Descrição
id	Integer	Chave primária da curtida.
dataset_id	Integer	Referência ao dataset curtido.
user_id	Integer	Referência ao usuário que curtiu.
created_at	Timestamp	Data de criação do registro.
updated_at	Timestamp	Data da alteração mais recente.

3.6.11 Entidade *dataset_favorites*

A entidade *dataset_favorites* registra os datasets favoritados por cada usuário, possibilitando acesso rápido a conjuntos de interesse pessoal. A Tabela 3.14 apresenta sua estrutura.

Tabela 3.14: Entidade *dataset_favorites*.

Coluna	Tipo	Descrição
id	Integer	Chave primária do favorito.
dataset_id	Integer	Referência ao dataset favoritado.
user_id	Integer	Referência ao usuário que favoritou.
created_at	Timestamp	Data de criação do registro.
updated_at	Timestamp	Data da alteração mais recente.

3.6.12 Entidade *audits*

A entidade *audits* registra as alterações realizadas nas entidades do sistema para fins de auditoria e rastreabilidade. Cada evento armazena o tipo da operação, os valores anteriores e posteriores, o usuário responsável e informações da requisição. A Tabela 3.15 apresenta sua estrutura.

Tabela 3.15: Entidade audits.

Coluna	Tipo	Descrição
id	Integer	Chave primária do registro de auditoria.
auditable_id	BigInt	ID da entidade auditada.
auditable_type	Varchar	Tipo da entidade auditada.
event	Varchar	Tipo de evento (created, updated, deleted).
old_values	JSON	Valores anteriores à alteração.
new_values	JSON	Valores posteriores à alteração.
user_id	Varchar	ID do usuário responsável pela alteração.
url	Varchar	URL da requisição que gerou a alteração.
ip_address	Varchar	Endereço IP da requisição.
user_agent	Varchar	User Agent da requisição.
created_at	Timestamp	Data de criação do registro.
updated_at	Timestamp	Data da alteração mais recente.

Capítulo 4

Implementação

Este capítulo apresenta as decisões técnicas adotadas na implementação do DataRural. A partir dos requisitos e da modelagem definidos no Capítulo 3, são discutidas a arquitetura da aplicação, as tecnologias selecionadas e as justificativas que motivaram cada escolha. O foco não é apenas descrever os componentes utilizados, mas argumentar por que determinadas abordagens foram preferidas a outras, considerando o contexto e as restrições do projeto.


4.1 Arquitetura da aplicação

A arquitetura do DataRural adota uma abordagem *fullstack* monolítica modular, na qual servidor, interface e persistência residem em um mesmo projeto, mas são organizados em domínios independentes. Essa decisão foi tomada em vez de separar a aplicação em uma API REST e um cliente dedicado porque, neste estágio do projeto, a complexidade de manter dois sistemas sincronizados — com duplicação de validações, permissões e contratos de dados — não se justifica. A abordagem integrada permite que uma alteração em uma regra de negócio seja refletida imediatamente na interface, sem necessidade de atualizar também um contrato de API.

O código é mantido em um **monorepo** gerenciado com **Turborepo** e **pnpm workspaces**. A aplicação web reside em **apps/web**, enquanto componentes reutilizá-

veis e configurações compartilhadas ficam em diretórios sob `packages/`. A alternativa de manter repositórios separados exigiria um processo de versionamento e publicação de pacotes entre os projetos, introduzindo complexidade que não se justifica para uma equipe pequena. Com o monorepo, alterações em componentes compartilhados, como o pacote `packages/ui`, são imediatamente visíveis na aplicação.

A estrutura do monorepo está organizada conforme apresentado a seguir:



A estrutura interna da aplicação foi dividida por domínios. Em vez de manter todos os modelos, controladores e componentes em diretórios globais, os recursos relacionados são aproximados em módulos como *auth*, *dataset*, *groups* e *users*. O módulo *auth* concentra cadastro, entrada, recuperação de acesso e demais operações relacionadas à sessão. O módulo *dataset* reúne os modelos e fluxos de publicação, consulta, edição e versionamento. O módulo *groups* trata a criação de equipes e a associação de membros, enquanto o módulo *users* mantém perfil e operações administrativas sobre contas. Essa divisão favorece a identificação do local responsável por uma regra e acompanha os conceitos apresentados no modelo de dados.

As requisições seguem um fluxo comum. Inicialmente, a rota identifica a operação solicitada e aplica os *middlewares* necessários. Em seguida, os dados de entrada

são validados e o controlador aciona os modelos ou serviços do domínio. Após a persistência, o servidor pode redirecionar o usuário ou renderizar uma página React por meio do Inertia.js. Operações com anexos incluem ainda a validação e o armazenamento do arquivo antes da confirmação da versão.

4.2 Decisões tecnológicas

A seleção das tecnologias considerou as necessidades funcionais do DataRural e a integração entre as diferentes partes da aplicação. Como o sistema reúne autenticação, formulários, persistência de metadados, envio de arquivos e páginas interativas, optou-se por uma pilha *fullstack* baseada em TypeScript. Essa escolha permite compartilhar conceitos e tipos entre servidor e interface, além de reduzir mudanças de contexto durante o desenvolvimento. As subseções a seguir apresentam cada componente da pilha adotada e justificam as decisões que motivaram sua escolha.

4.2.1 Servidor: AdonisJS e TypeScript

O AdonisJS foi escolhido como *framework* do lado servidor. O problema a ser resolvido nesta camada envolve validar entrada de dados, verificar identidade e permissões, orquestrar operações sobre múltiplas entidades relacionais e gerenciar anexos de arquivos — tudo isso em cada requisição. Um *framework* que oferece esses recursos de forma integrada reduz o número de decisões de cola e diminui a superfície de incompatibilidades entre bibliotecas independentes.

A escolha considerou alternativas como NestJS, Express e Fastify. O NestJS oferece uma arquitetura baseada em decorators e injeção de dependências, mas adiciona uma camada de abstração que se mostrou desnecessária para o escopo deste projeto. O Express e o Fastify fornecem menor estrutura nativa: cada funcionalidade — validação, ORM, autenticação, autorização — precisa ser adicionada por meio de bibliotecas de terceiros, o que aumenta o custo de integração e manutenção. O AdonisJS foi preferido porque integra nativamente rotas, controladores, validações, *middlewares*, políticas de autorização, ORM (Lucid) e suporte a sessões, além de

oferecer integração direta com o Inertia.js.

O uso de TypeScript contribui para explicitar os formatos esperados pelos métodos e pelas entidades. Essa característica é especialmente útil no tratamento de datasets, versões e arquivos, pois reduz ambiguidades entre os identificadores e os metadados manipulados em cada etapa.

4.2.2 Interface: React e Inertia.js

O React foi adotado para a construção da interface. A principal decisão nesta camada não foi qual biblioteca de componentes usar, mas como conectar o servidor à interface sem duplicar regras de negócio. A abordagem convencional — uma API REST consumida por um cliente separado — exige que validações, permissões e transformações de dados sejam expressas duas vezes: uma no servidor e outra no cliente. O Inertia.js resolve esse problema ao eliminar a API intermediária. O servidor resolve a rota, consulta os dados necessários e entrega as propriedades da página ao componente React correspondente. As navegações seguintes são realizadas sem recarga integral do documento, mantendo a experiência de uma aplicação de página única.

Foram consideradas alternativas como Vue.js e Angular para a camada de componentes. O Vue oferece uma curva de aprendizado menor, mas possui um ecossistema relativamente menor para as necessidades do projeto. O Angular adota uma estrutura mais rígida e complexa. O React foi escolhido por combinar flexibilidade, ecossistema extenso de bibliotecas de componentes e familiaridade dos autores com sua abordagem.

4.2.3 Persistência: PostgreSQL e Lucid ORM

O PostgreSQL armazena os dados relacionais da plataforma. A adoção de um banco relacional é adequada ao domínio porque as associações possuem significado direto e precisam manter integridade referencial: uma versão deve pertencer a um dataset existente, um membro deve referenciar um usuário e um grupo, e a licença

associada deve corresponder a uma opção cadastrada.

O acesso ao banco é realizado por meio do Lucid ORM, integrado ao AdonisJS. Os modelos representam as entidades apresentadas no Capítulo 3, enquanto as migrações registram a evolução do esquema. Dessa forma, a estrutura das tabelas pode ser recriada de modo controlado em diferentes ambientes.

Os arquivos CSV não são armazenados nas tabelas relacionais. O banco mantém os metadados e as referências para os anexos, separando as consultas da aplicação do armazenamento físico. Essa decisão evita transformar o banco em um repositório de objetos binários e facilita uma futura substituição do armazenamento local por um serviço de objetos.

4.2.4 Armazenamento de arquivos

O envio e a recuperação dos arquivos são tratados pelo pacote `@jrmc/adonis-attachment`. Na configuração adotada, os anexos são mantidos em `storage/uploads`, e o banco registra os metadados necessários para localizá-los. A abstração de armazenamento impede que os controladores dependam diretamente de operações específicas do sistema de arquivos, facilitando uma eventual migração para armazenamento em nuvem.

Cada versão pode possuir mais de um CSV, conforme previsto pelo requisito RF-02. A entidade `dataset_version_files` registra cada anexo individualmente, incluindo seu nome, posição e indicação de arquivo principal. Além dos CSV enviados, o sistema gera um arquivo `README.md` para cada nova versão, consolidando informações descritivas existentes no momento da publicação.

4.2.5 Interface e componentes visuais

A interface utiliza um sistema de design próprio, desenvolvido com CSS convencional e variáveis CSS. Os componentes reutilizáveis ficam no pacote `packages/ui`, separando elementos genéricos das páginas específicas da plataforma. O Radix UI é utilizado de forma pontual, apenas nos componentes em que suas primitivas são

necessárias, não constituindo a base de toda a interface. O conjunto foi estruturado para responder a diferentes larguras de tela.

4.2.6 Ambiente de desenvolvimento

No ambiente de desenvolvimento, o PostgreSQL, o pgAdmin e o Mailpit são executados em contêineres Docker. O pgAdmin auxilia na inspeção do banco de dados, e o Mailpit recebe as mensagens de e-mail geradas pela aplicação. A utilização de contêineres torna esses serviços reproduzíveis e reduz diferenças de configuração entre as máquinas dos desenvolvedores.

4.3 Implementação do controle de acesso

O DataRural permite a consulta de conteúdo público sem autenticação, mas exige uma conta para ações que alteram o estado da plataforma. Cadastro, autenticação e edição de perfil utilizam os recursos de sessão do AdonisJS, seguindo os princípios definidos na Seção 3.5 do Capítulo 3.

Os dados informados na tela de autenticação são transmitidos sob proteção contra *Cross-Site Request Forgery* (CSRF) gerenciada pelo módulo Shield do AdonisJS, assegurando que apenas requisições originadas na própria aplicação possam estabelecer sessões autenticadas.

Rotas de publicação, gerenciamento de grupos, favoritos e administração são protegidas por *middleware* de autenticação. A autorização específica considera a autoria do dataset, o grupo associado e o papel exercido pelo usuário na tabela *group_members*. Nos datasets individuais, o proprietário controla edição, alteração de visibilidade e exclusão. Nos datasets vinculados a grupos, a permissão é calculada a partir do papel registrado em *group_members*.

O painel administrativo aplica uma verificação adicional baseada no papel global registrado na tabela *roles*. A separação entre papel global e papel contextual, definida na Seção 3.5 do Capítulo 3, é implementada por meio de duas consultas distintas:

uma ao campo *role_id* do usuário e outra à associação em *group_members*.

4.4 Implementação do versionamento

O fluxo de publicação cria o registro do dataset, sua versão inicial e os registros correspondentes aos arquivos em uma única transação relacional. Essas operações formam uma unidade lógica atômica: não é permitido manter um dataset sem versão ou uma versão sem seus anexos físicos correspondentes.

Atualizações de conteúdo geram uma versão subsequente, conforme o mecanismo de versionamento fundamentado no Capítulo 2. O responsável acessa o dataset existente, envia os novos arquivos e confirma a criação.

A exclusão de uma versão utiliza exclusão lógica. Na prática, a aplicação altera o indicador *is_deleted* da entidade *dataset_versions*. Versões nessa condição deixam de aparecer nos fluxos comuns, mas ainda podem ser restauradas caso seja necessário.

Para download, o usuário pode selecionar um arquivo específico ou solicitar todos os arquivos da versão, que são reunidos em um pacote ZIP. O download respeita a mesma política de acesso usada na visualização.

4.5 Implementação da exploração de dados

A prévia tabular interativa é processada no navegador: o componente interpreta o conteúdo do CSV no lado cliente e constrói a tabela apresentada ao usuário, permitindo reconhecer colunas e observar exemplos de valores antes do download completo.

As curtidas e os favoritos são armazenados separadamente porque representam intenções diferentes. As curtidas funcionam como interação pública, enquanto os favoritos criam uma coleção pessoal. Nenhuma das duas ações altera a propriedade ou a visibilidade do conjunto.

4.6 Implementação da auditoria

As alterações sobre entidades relevantes produzem registros de auditoria. Para cada evento, são armazenados o tipo da operação, os valores anteriores e posteriores, o usuário responsável e informações da requisição. Versionamento e auditoria possuem finalidades relacionadas, mas não idênticas: o primeiro preserva a evolução dos arquivos de um dataset, a segunda registra mudanças nas entidades da aplicação. Uma edição de descrição, por exemplo, pode gerar um evento de auditoria sem criar uma nova versão de arquivos. A combinação dos dois mecanismos amplia a rastreabilidade da plataforma.

4.7 Atendimento à proposta

A implementação concretiza os elementos centrais definidos no capítulo anterior. A publicação de múltiplos CSV, os metadados, as licenças e a prévia tabular atendem à organização e à compreensão dos conjuntos. O histórico de versões, a exclusão lógica e a auditoria oferecem mecanismos de rastreabilidade. Os grupos e a distinção entre conteúdo público e privado atendem aos cenários de colaboração e controle de acesso.

Em relação aos trabalhos relacionados, o DataRural incorpora práticas encontradas em plataformas de dados, mas as aplica a um escopo institucional. A exploração e as interações lembram recursos presentes em plataformas comunitárias; o registro de metadados e licenças aproxima a solução de repositórios científicos; e os grupos acrescentam uma camada voltada ao trabalho interno de equipes da universidade.

O estágio atual também delimita o alcance da solução. O CSV é o formato inicialmente suportado, o armazenamento utiliza o sistema de arquivos local e a análise apresentada na interface é intencionalmente limitada a uma prévia. Essas decisões mantêm a implementação compatível com o escopo do projeto e deixam pontos de extensão para formatos adicionais, armazenamento de objetos e mecanismos mais avançados de validação e visualização.

Capítulo 5

Conclusão

Este capítulo apresenta as considerações finais sobre o desenvolvimento do DataRural. Inicialmente, são retomados o objetivo do trabalho e os principais resultados alcançados com a construção da plataforma. Em seguida, são discutidas as limitações do estágio atual e as possibilidades de continuidade do projeto.

5.1 Considerações finais

O trabalho teve como objetivo projetar e desenvolver uma plataforma institucional para apoiar a publicação, a organização, a consulta e o compartilhamento de datasets da UFRRJ. A proposta foi motivada pela necessidade de oferecer aos dados um tratamento que não se limitasse ao armazenamento de arquivos, incorporando informações descritivas, condições de acesso, autoria e histórico de atualizações.

Como resultado, foi desenvolvido o DataRural, uma aplicação web capaz de receber um ou mais arquivos CSV por versão e associá-los aos metadados definidos para o dataset. A plataforma disponibiliza consulta e download de conteúdos públicos sem exigir autenticação, ao mesmo tempo que reserva as operações de publicação e gerenciamento aos usuários identificados. A busca, os filtros por área temática e a prévia tabular complementam esse fluxo, permitindo observar o contexto e parte da estrutura do material antes de obtê-lo.

O versionamento constitui um dos resultados centrais da implementação. Em vez de substituir os arquivos de uma publicação, cada atualização pode ser registrada separadamente, mantendo a relação com o dataset original. A exclusão lógica e a possibilidade de restauração complementam esse mecanismo, enquanto os registros de auditoria documentam alterações realizadas nas entidades da aplicação. Esses recursos concretizam os requisitos de preservação do histórico apresentados no Capítulo 3.

A colaboração foi incorporada por meio de grupos e papéis contextuais. Essa organização permite que um dataset seja mantido por uma equipe sem conceder as mesmas permissões a todos os participantes. A separação entre datasets públicos e privados também possibilita utilizar a plataforma tanto para divulgação quanto para atividades internas. As verificações de acesso são executadas no servidor e utilizam a propriedade do conjunto, sua associação a um grupo e o papel exercido pelo usuário.

Do ponto de vista técnico, a aplicação foi organizada em módulos correspondentes aos principais domínios do sistema. A integração entre AdonisJS, React e Inertia.js permitiu manter o processamento das requisições e das permissões no servidor, oferecendo uma interface composta por elementos reutilizáveis. O PostgreSQL concentra os dados relacionais, enquanto os anexos permanecem separados e são associados às respectivas versões. A implementação descrita no Capítulo 4 fornece, portanto, uma base funcional para a continuidade do DataRural.

O trabalho não procura substituir repositórios científicos de alcance amplo ou plataformas comunitárias já consolidadas. Sua contribuição está na reunião de recursos de publicação, controle de acesso, colaboração e acompanhamento de versões em uma solução direcionada ao contexto institucional apresentado. Com isso, o projeto demonstra como os requisitos levantados podem ser transformados em um sistema único, mantendo pontos de extensão para necessidades que ultrapassam o escopo desta etapa.

5.2 Limitações e trabalhos futuros

O estágio atual do DataRural apresenta limitações que orientam possíveis trabalhos futuros. A primeira está relacionada aos formatos aceitos. A publicação foi implementada inicialmente para arquivos CSV, com limite de 25 MB por arquivo. Embora esse recorte atenda ao objetivo definido para o projeto, ele não contempla outros materiais que podem acompanhar uma pesquisa, como *notebooks* e outros formatos de arquivo tabulares. Uma extensão da plataforma pode criar validadores e visualizadores específicos para novos formatos, preservando o modelo de metadados e versões já adotado.

O tratamento do próprio CSV também pode ser ampliado. A visualização atual apresenta uma amostra tabular e o indicador de usabilidade considera aspectos estruturais observados durante o envio. Esses recursos não verificam a validade científica dos valores nem substituem a documentação produzida pelo responsável. Como continuidade, podem ser acrescentados dicionários de dados, identificação configurável de delimitadores e codificações, regras de validação por coluna e comparações entre versões. Essas funcionalidades permitiriam informar com maior detalhe como a estrutura do conjunto se altera ao longo do tempo.

Outra possibilidade relevante para trabalhos futuros é a disponibilização de uma interface de programação de aplicações (API) voltada ao consumo programático de dados. No estágio atual, o acesso e a reutilização dos datasets dependem primordialmente da interface web e do download manual dos arquivos. A implementação de uma API RESTful ou de *endpoints* dedicados permitiria a integração direta com *scripts* e fluxos automatizados de análise de dados, além de viabilizar consultas paginadas e filtragens parciais sem a necessidade de transferir o arquivo integral. Esse recurso ampliaria a interoperabilidade do DataRural com sistemas externos e ambientes de pesquisa computacional, aplicando mecanismos de autenticação por *tokens* para assegurar o respeito às políticas de acesso e aos papéis definidos na plataforma.

A implementação priorizou os fluxos funcionais da plataforma e não incluiu, no

escopo apresentado, uma avaliação sistemática com usuários da universidade. Dessa forma, não é possível concluir, a partir deste trabalho, como diferentes públicos percebem a facilidade de uso ou quais metadados consideram mais importantes durante a publicação e a busca. Estudos futuros podem conduzir testes de usabilidade com pesquisadores, estudantes e servidores, utilizando os resultados para revisar os formulários, a navegação, os papéis dos grupos e a apresentação das informações.

Também são necessárias avaliações técnicas antes de uma disponibilização institucional em maior escala. Testes de carga podem observar o comportamento da aplicação com volumes superiores de arquivos e acessos simultâneos, enquanto testes de segurança podem examinar os fluxos de autenticação, autorização e download. Testes automatizados também podem ser acrescentados para verificar as regras de negócio, especialmente nos cenários que combinam propriedade, visibilidade e papéis de grupo.

Por fim, a evolução do DataRural pode incluir integração com serviços institucionais de identidade, maior suporte a internacionalização e mecanismos de identificação persistente para publicações que necessitem de citação formal. Integrações com outros repositórios e catálogos também podem evitar que o acervo permaneça isolado. Essas extensões devem manter a separação de responsabilidades da arquitetura atual e ser acompanhadas por definições institucionais sobre curadoria, privacidade, licenciamento e conservação dos dados.

Referências

BERNSTEIN, P. A. Middleware: A model for distributed system services. *Communications of the ACM*, v. 39, n. 2, p. 86–98, 1996.

BORGMAN, C. L. The conundrum of sharing research data. *Journal of the American Society for Information Science and Technology*, v. 63, n. 6, p. 1059–1078, 2012. Disponível em: <<https://doi.org/10.1002/asi.22634>>.

Brasil. *Lei nº 13.709, de 14 de agosto de 2018: Lei Geral de Proteção de Dados Pessoais (LGPD)*. [S.l.], 2018. Disponível em: <https://www.planalto.gov.br/ccivil_03/_ato2015-2018/2018/lei/l13709.htm>. Acesso em: 05 set. 2026.

Creative Commons. *About CC Licenses*. [S.l.], 2026. Disponível em: <<https://creativecommons.org/share-your-work/cclicenses/>>. Acesso em: 18 ago. 2026.

Creative Commons. *CC0 1.0 Universal: Public Domain Dedication*. [S.l.], 2026. Disponível em: <<https://creativecommons.org/publicdomain/zero/1.0/>>. Acesso em: 18 ago. 2026.

DataCite. *Versioning*. [S.l.], 2026. Disponível em: <<https://support.datacite.org/docs/versioning>>. Acesso em: 18 ago. 2026.

GO FAIR Initiative. *FAIR Principles: Findable, Accessible, Interoperable, Reusable*. [S.l.], 2026. Disponível em: <<https://www.go-fair.org/fair-principles/>>. Acesso em: 18 ago. 2026.

HIGGINS, S. The DCC curation lifecycle model. *International Journal of Digital Curation*, v. 3, n. 1, p. 134–140, 2008. Disponível em: <<https://doi.org/10.2218/ijdc.v3i1.48>>.

KLUMP, J. et al. Versioning data is about more than revisions: A conceptual framework and proposed principles. *Data Science Journal*, v. 20, n. 12, p. 1–13, 2021. Disponível em: <<https://doi.org/10.5334/dsj-2021-012>>.

Open Data Commons. *Open Database License (ODbL) v1.0*. [S.l.], 2026. Disponível em: <<https://opendatacommons.org/licenses/odbl/1-0/>>. Acesso em: 18 ago. 2026.

Open Knowledge Foundation. *Open Data Handbook: What is Open Data?* [S.l.], 2015. Disponível em: <<https://opendatahandbook.org/guide/en/what-is-open-data/>>. Acesso em: 18 ago. 2026.

OWASP Foundation. *Authentication Cheat Sheet*. [S.l.], 2026. Disponível em: <https://cheatsheetseries.owasp.org/cheatsheets/Authentication_Cheat_Sheet.html>. Acesso em: 18 ago. 2026.

OWASP Foundation. *Session Management Cheat Sheet*. [S.l.], 2026. Disponível em: <https://cheatsheetseries.owasp.org/cheatsheets/Session_Management_Cheat_Sheet.html>. Acesso em: 18 ago. 2026.

PAMPEL, H. et al. Making research data repositories visible: The re3data.org registry. *PLOS ONE*, v. 8, n. 11, p. e78080, 2013. Disponível em: <<https://doi.org/10.1371/journal.pone.0078080>>.

RILEY, J. *Understanding Metadata: What is Metadata, and What is it For?* [S.l.], 2017. Disponível em: <<https://www.niso.org/publications/understanding-metadata-2017>>. Acesso em: 18 ago. 2026.

SANDHU, R.; FERRAILOLO, D. F.; KUHN, D. R. The nist model for role-based access control: Towards a unified standard. In: *Proceedings of the Fifth ACM Workshop on Role-Based Access Control*. [s.n.], 2000. p. 47–63. Disponível em: <<https://doi.org/10.1145/344287.344301>>.

SHAFRANOVICH, Y. *Common Format and MIME Type for Comma-Separated Values (CSV) Files*. [S.l.], 2005. Disponível em: <<https://www.rfc-editor.org/rfc/rfc4180>>. Acesso em: 18 ago. 2026.

TEMOSHOK, D. et al. *Digital Identity Guidelines: Authentication and Authenticator Management*. [S.l.], 2025. Disponível em: <<https://pages.nist.gov/800-63-4/sp800-63b.html>>. Acesso em: 18 ago. 2026.

TENNISON, J.; KELLOGG, G.; HERMAN, I. *Model for Tabular Data and Metadata on the Web*. [S.l.], 2015. Disponível em: <<https://www.w3.org/TR/2015/REC-tabular-data-model-20151217/>>. Acesso em: 18 ago. 2026.

WILKINSON, M. D. et al. The fair guiding principles for scientific data management and stewardship. *Scientific Data*, v. 3, n. 160018, 2016. Disponível em: <<https://doi.org/10.1038/sdata.2016.18>>.